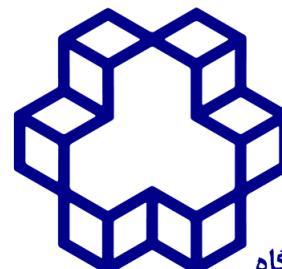


بسم الله الرحمن الرحيم



دانشگاه
خواجه نصیرالدین طوسی
K. N. Toosi University
of Technology

گزارش پروژه پایانی درس یادگیری ماشین

عنوان پروژه: به کارگیری Multi-View Learning برای تشخیص خطای یاتاقان‌ها با استفاده از داده‌های ارتعاش

Python Code and Output Notebook

نگارش: علی شعبانیپور مقدم

شماره دانشجویی: ۴۰۲۰۷۳۰۴

استاد درس: دکتر مهدی علیاری شوره دلی

تابستان ۱۴۰۴

فهرست مطالب

۱	مقدمه	
۳	دادگان و ویژگی‌ها	۱.۱
۴	چرا چند نما؟	۲.۱
۵		
۶	شبيه‌سازی و انجام پروژه	۲
۶	آموزش بدون ویژگی و با داده خام	۱.۲
۸	پيش‌پردازش و آماده‌سازی ویژگی‌ها	۲.۲
۱۰	هدف اصلی پروژه و تغيير در پياده‌سازی	۳.۲
۱۴	طراحی طبقه‌بند برای ده کلاس و انتخاب ویژگی‌ها	۴.۲
۱۵	تفاوت فيوژن در سطح ویژگی و فيوژن در سطح تصميم	۵.۲
۲۱	نتایج ارزیابی مدل‌ها	۶.۲
۲۲	مقایسه نتایج فيوژن در سطح ویژگی و سطح تصميم با ۳ ویژگی در هر نما	۷.۲
۲۵	نتایج فيوژن در سطح ویژگی با دو فیچر در هر ویو	۸.۲
۲۶	نمای صدا و نقش آن در تشخيص خطأ	۹.۲
۲۸	كاربرد داده‌های چند ميكروفونه در تشخيص خطأ	۱۰.۲
۲۹	ویژگی‌های آکوستيکي مهم در تشخيص خطأ تبيين و مصورسازی	۱۱.۲
۳۲	جمع‌بندی و نتيجه‌گيري	۱۲.۲



۱ مقدمه

یاتاقان‌ها از جمله اجزای اساسی در ماشین‌آلات صنعتی محسوب می‌شوند که نقش حیاتی در انتقال بار، کاهش اصطکاک و تضمین پایداری عملکرد سیستم‌های دوار دارند. خرابی در یاتاقان‌ها نه تنها موجب کاهش بازدهی و کارایی ماشین می‌شود، بلکه می‌تواند منجر به توقف ناگهانی خط تولید، افزایش هزینه‌های تعمیر و نگهداری، و در مواردی خسارت‌های جبران‌ناپذیر به کل سیستم گردد. از این‌رو، توسعه روش‌های کارآمد و دقیق برای تشخیص و پیش‌بینی خرابی یاتاقان‌ها به یکی از موضوعات مهم در حوزه مهندسی مکانیک و هوش مصنوعی تبدیل شده است.

روش‌های سنتی عیب‌یابی عمدتاً بر پایه تحلیل یکبعدی داده‌های ارتعاشات در حوزه زمان یا حوزه فرکانس استوار بوده‌اند. این رویکردها هرچند در شرایطی می‌توانند اطلاعات ارزشمندی فراهم کنند، اما به دلیل محدود بودن به یک دیدگاه خاص، قادر به بهره‌برداری کامل از تمامی ابعاد اطلاعاتی موجود در سیگنال‌های ارتعاشی نیستند. برای مثال، تحلیل در حوزه زمان الگوهای گذرا و تغییرات لحظه‌ای را برجسته می‌سازد، در حالی که تحلیل در حوزه فرکانس عمدتاً بر مؤلفه‌های تناوبی و طیفی تمرکز دارد. همچنین، تحلیل حوزه زمان-فرکانس نظری Scalogram یا Spectrogram امکان بررسی رفتار دینامیکی سیستم در هر دو بعد زمان و فرکانس را به طور همزمان فراهم می‌کند. بدین ترتیب، استفاده از تنها یک نما (View) از داده‌ها می‌تواند منجر به از دست رفتن بخش قابل توجهی از اطلاعات مؤثر در فرآیند تشخیص گردد.

با ظهور روش‌های نوین در یادگیری ماشین، رویکرد Multi-View Learning به عنوان راهکاری پیشرفته برای غلبه بر این محدودیت‌ها معرفی شده است. در این روش، داده‌های خام ارتعاشی به نمایه‌ای مختلفی مانند حوزه زمان، حوزه فرکانس و حوزه زمان-فرکانس تبدیل می‌شوند. سپس برای هر نما مجموعه‌ای از ویژگی‌ها استخراج شده و مدل‌های یادگیری ماشین به صورت جداگانه آموزش داده می‌شوند. ترکیب نتایج به دست آمده از این نمایه‌ها می‌تواند موجب افزایش دقت پیش‌بینی، کاهش خطای تشخیص و بهبود قابلیت اطمینان سیستم گردد. در این پروژه، هدف اصلی ارائه و ارزیابی یک چارچوب مبتنی بر Multi-View Learning برای تشخیص خرابی یاتاقان‌ها است. در این راستا، ابتدا داده‌ها از مجموعه‌های معتبر و پرکاربرد در این حوزه استخراج می‌شوند. سپس ویژگی‌های گوناگون در هر یک از نمایه‌ها محاسبه و مدل‌های متنوع یادگیری ماشین بر اساس آن‌ها آموزش داده خواهند شد. در ادامه، عملکرد مدل‌ها با استفاده از معیارهای شناخته‌شده‌ای همچون دقت (Accuracy)، یادآوری (Recall)، دقت (Precision) و معیار ترکیبی F1-score مورد ارزیابی قرار می‌گیرد. در نهایت، نتایج به دست آمده تحلیل و مقایسه می‌شوند تا میزان کارایی و اثربخشی این رویکرد مشخص گردد و زمینه برای توسعه روش‌های پیشرفته‌تر در آینده فراهم شود.

۱.۱ دادگان و ویژگی‌ها

در این پژوهش از پایگاه داده MaFaulDa Bearing Dataset استفاده شده است که یکی از مجموعه داده‌های معترض و پرکاربرد در زمینه تشخیص خرابی یاتاقان‌ها به شمار می‌رود. این دادگان در یک بستر آزمایشگاهی کنترل شده و تحت شرایط گوناگون عملکردی گردآوری شده و شامل سیگنال‌های ارتعاشی و صوتی مربوط به یاتاقان‌های سالم و معیوب می‌باشد.

هر توالی داده با نرخ نمونهبرداری ۵۰ kHz به مدت ۵ ثانیه ثبت شده است و بنابراین هر توالی شامل ۲۵۰,۰۰۰ نمونه خام می‌باشد. این ویژگی باعث می‌شود که داده‌ها از دقت زمانی بالایی برخوردار باشند و امکان استخراج ویژگی‌های متنوع در حوزه‌های مختلف تحلیل سیگنال فراهم گردد. کل مجموعه داده شامل ۱۹۵۱ توالی مستقل است که شرایط مختلف عملکرد یاتاقان‌ها را پوشش می‌دهد. این شرایط شامل حالت سالم، ناترازی (Misalignment) در دو حالت افقی و عمودی، عدم تعادل (Imbalance) و همچنین خرابی‌های مختلف در اجزای یاتاقان‌ها (قفسه، ساقمه و مسیر بیرونی) در دو موقعیت زیرین (Underhang) و رویی (Overhang) می‌باشد.

Sequence	Measurements
Normal	49
Horizontal misalignment	197
Vertical misalignment	301
Imbalance	333
Underhang bearing	
Cage fault	188
Outer race fault	184
Ball fault	186
Overhang bearing	
Cage fault	188
Outer race fault	188
Ball fault	137
Total	1951

همان‌طور که در جدول بالا مشاهده می‌شود، این پایگاه داده شامل شرایط سالم و همچنین دسته‌بندی متنوعی از خطاهای یاتاقان است که تنوع بالایی از حالات واقعی را پوشش می‌دهد.

ساختار فایل‌های داده

داده‌ها به صورت فایل‌های CSV ذخیره‌سازی شده‌اند. هر فایل شامل ۸ ستون مربوط به سیگنال‌های مختلف اندازه‌گیری است که در جدول زیر نشان داده شده‌اند:

Column	Description
1	Tachometer signal (used to estimate rotation frequency)
2–4	Underhang bearing accelerometer signals (Axial, Radial, Tangential)
5–7	Overhang bearing accelerometer signals (Axial, Radial, Tangential)
8	Microphone signal

ویژگی‌های خاص دادگان

- تغییرات سرعت دوران موتور در بازه ۷۳۷ rpm تا ۳۶۸۶ rpm با گام‌های تقریبی ۶۰ دور بر دقیقه. - ثبت همزمان سیگنال‌های ارتعاشی و صوتی با نرخ نمونهبرداری بالا (۵۰ kHz). - تنوع در حالات خرابی (یاتاقان زیرین و رویی) و شرایط ناترازی و عدم تعادل. - فراهم‌سازی بستر مناسب برای تحلیل چندنما (Multi-View) و یادگیری ماشین.

در مجموع، پایگاه داده MaFaulDa با توجه به گستردگی شرایط پوشش داده شده، کیفیت بالای ثبت سیگنال‌ها و ترکیب حسگرهای ارتعاشی و صوتی، انتخابی مناسب برای پژوهش‌های مبتنی بر یادگیری ماشین و به ویژه رویکردهای چندنما محاسب می‌شود. این ویژگی‌ها امکان استخراج و تحلیل الگوهای پیچیده در داده‌ها را فراهم کرده و زمینه را برای توسعه چارچوب‌های تشخیص خطای پیشرفته هموار می‌سازد.



۲.۱ چرا چند نما؟

تشخیص خرابی در یاتاقان‌ها به دلیل پیچیدگی سیگنال‌های ارتعاشی همواره با چالش همراه بوده است. این سیگنال‌ها معمولاً غیرایستا هستند و الگوهای مختلفی از خطاهای را در خود پنهان دارند که تنها با نگاه به یک حوزه از داده‌ها نمی‌توان به طور کامل آن‌ها را آشکار ساخت. به همین دلیل، استفاده از نماهای مختلف (Views) از سیگنال به عنوان یک راهکار اساسی در نظر گرفته می‌شود.

حوزه زمان (Time Domain) در این نما ویژگی‌هایی نظیر Kurtosis، RMS و Skewness استخراج می‌شوند. این شاخص‌ها قادرند تغییرات لحظه‌ای و گذرای سیگنال را توصیف کنند. چنین تغییراتی معمولاً در مراحل اولیه بروز خرابی قابل مشاهده هستند.

حوزه فرکانس (Frequency Domain) با استفاده از تبدیل فوریه (FFT) می‌توان مؤلفه‌های تناوبی و انرژی سیگنال را در باندهای مختلف فرکانسی بررسی کرد. این نما برای آشکارسازی الگوهای تکرارشونده که به دلیل آسیب در اجزای مکانیکی ظاهر می‌شوند بسیار مؤثر است.

حوزه زمان-فرکانس (Time-Frequency Domain) روش‌هایی مانند Scalogram یا Spectrogram امکان تحلیل سیگنال در هر دو بعد زمان و فرکانس را فراهم می‌کنند. این نما برای سیگنال‌های غیرایستا اهمیت ویژه‌ای دارد، چرا که می‌تواند تغییرات فرکانسی را در طول زمان ردیابی کند.

استفاده از هر یک از این نماها به تنها ی قادر به ارائه بخشی از اطلاعات است، اما محدودیت‌هایی نیز به همراه دارد. به طور مثال، حوزه زمان ممکن است برای تشخیص الگوهای تناوبی ناکافی باشد و حوزه فرکانس توانایی توصیف تغییرات گزرا لحظه‌ای را ندارد. ترکیب این نماها در چارچوب Multi-View Learning باعث می‌شود که مدل‌های یادگیری ماشین به نمایی جامع‌تر از داده‌ها دسترسی داشته باشند و در نتیجه دقت و قابلیت اطمینان در فرآیند تشخیص خطای افزایش یابد.



۲ شبیه‌سازی و انجام پروژه

۱.۲ آموزش بدون ویژگی و با داده خام

یکی از رویکردهای اولیه در مسئله تشخیص خرابی یاتاقان، آموزش مدل‌های یادگیری ماشین مستقیماً بر روی داده‌های خام است. در این حالت، سیگنال ارتعاشی یا صوتی بدون انجام هیچ‌گونه استخراج ویژگی یا تبدیل به حوزه‌های دیگر (زمان، فرکانس یا زمان-فرکانس) به عنوان ورودی به مدل داده می‌شود. هرچند این روش ساده‌ترین راهکار محسوب می‌شود، اما با محدودیت‌ها و کاستی‌های متعددی روبرو است.

نخست آنکه داده‌های خام حجمی بسیار بالا دارند (برای مثال هر توالی شامل ۲۵۰ هزار نمونه است) و پردازش مستقیم آن‌ها نیازمند منابع محاسباتی سنگین می‌باشد. این امر علاوه بر افزایش زمان آموزش، می‌تواند موجب بروز مشکلاتی در همگرایی مدل شود.

دوم آنکه داده خام سیگنال‌ها اغلب شامل نویز و نوسانات غیرمرتبط است. در چنین شرایطی مدل ممکن است به جای یادگیری الگوهای مربوط به خرابی، به نویزها یا تغییرات تصادفی واپس‌نهاده گردد و در نتیجه عملکرد ضعیفی در تعیین به داده‌های جدید داشته باشد.

سومین مشکل این رویکرد آن است که سیگنال‌های ارتعاشی ماهیتی غیرایستا دارند و الگوهای مربوط به خرابی در حوزه‌های دیگر (مانند فرکانس یا زمان-فرکانس) آشکارتر هستند. بنابراین صرفاً تکیه بر داده خام می‌تواند موجب از دست رفتن بخش مهمی از اطلاعات گردد.

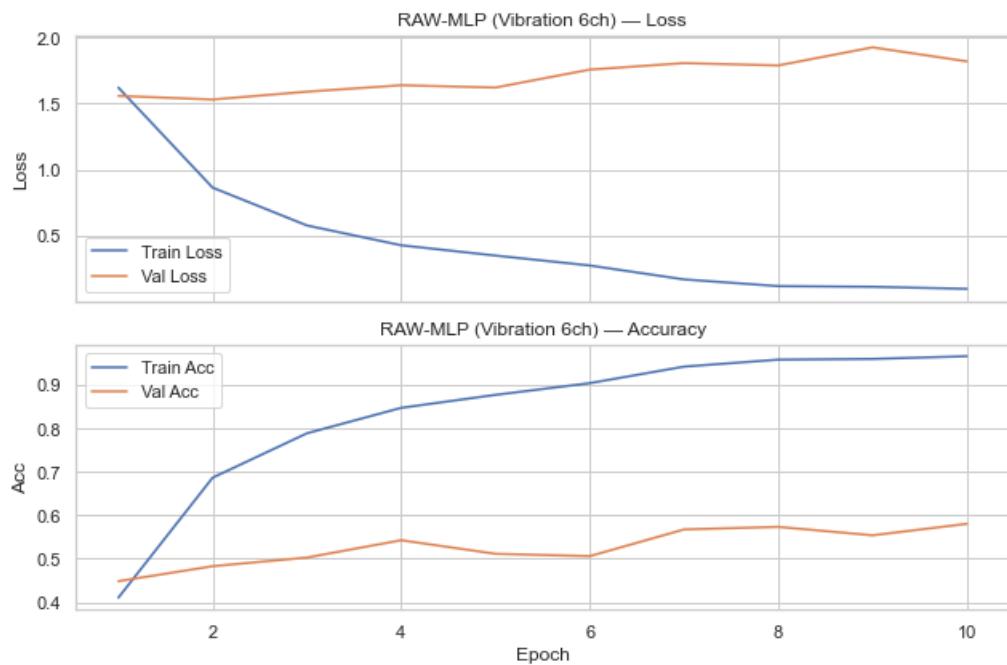
به همین دلایل، آموزش مستقیم بر روی داده‌های خام معمولاً نتایج رضایت‌بخشی ارائه نمی‌دهد و در مقایسه با روش‌های مبتنی بر استخراج ویژگی‌های مهندسی‌شده یا نمایه‌ای مختلف، دقت و قابلیت اطمینان کمتری دارد.

در زیر نیز نتایج آموزش بر روی داده خام مشاهده می‌شود:

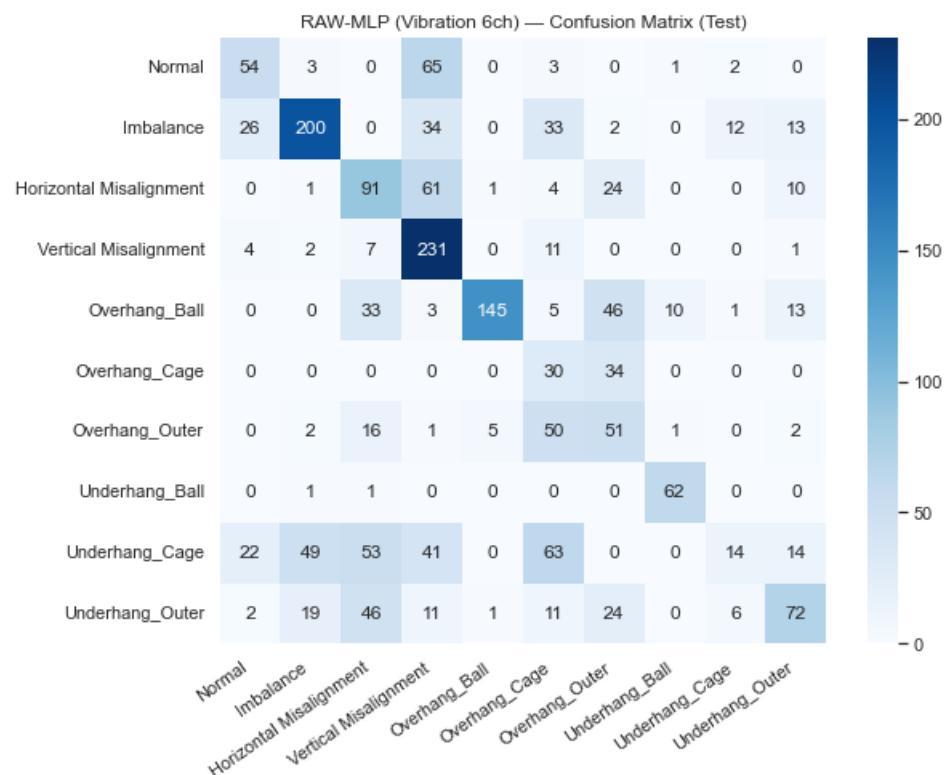
```
Input dim: 30000 (expected ~ 30000)
[RAW-MLP (Vibration 6ch) ep001] tr_loss=1.6226 tr_acc=0.410 | val_loss=1.5596 val_acc=0.448
[RAW-MLP (Vibration 6ch) ep002] tr_loss=0.8637 tr_acc=0.686 | val_loss=1.5319 val_acc=0.483
[RAW-MLP (Vibration 6ch) ep003] tr_loss=0.5770 tr_acc=0.789 | val_loss=1.5914 val_acc=0.503
[RAW-MLP (Vibration 6ch) ep004] tr_loss=0.4266 tr_acc=0.847 | val_loss=1.6402 val_acc=0.543
[RAW-MLP (Vibration 6ch) ep005] tr_loss=0.3486 tr_acc=0.877 | val_loss=1.6227 val_acc=0.511
[RAW-MLP (Vibration 6ch) ep006] tr_loss=0.2734 tr_acc=0.904 | val_loss=1.7587 val_acc=0.506
[RAW-MLP (Vibration 6ch) ep007] tr_loss=0.1678 tr_acc=0.942 | val_loss=1.8079 val_acc=0.567
[RAW-MLP (Vibration 6ch) ep008] tr_loss=0.1169 tr_acc=0.958 | val_loss=1.7903 val_acc=0.573
[RAW-MLP (Vibration 6ch) ep009] tr_loss=0.1118 tr_acc=0.960 | val_loss=1.9276 val_acc=0.554
[RAW-MLP (Vibration 6ch) ep010] tr_loss=0.0965 tr_acc=0.966 | val_loss=1.8213 val_acc=0.580
Early stop at ep10, best ep2 val_loss=1.5319

[RAW-MLP (Vibration 6ch)] TEST acc=0.5119 macro-F1=0.4908
```

شکل ۱: نتایج آموزش مدل بر روی داده‌های خام بدون استخراج ویژگی



شکل ۲: نتایج آموزش مدل روی داده های خام بدون ویزگی



شکل ۳: نتایج آموزش مدل بر روی داده های خام بدون استخراج ویزگی



۲.۲ پیش‌پردازش و آماده‌سازی ویژگی‌ها

پیش از آموزش مدل‌ها، داده‌های استخراج شده نیازمند نرمال‌سازی و استانداردسازی بودند تا اثر مقیاس‌های متفاوت ویژگی‌ها بر فرآیند یادگیری کاهش یابد. در غیر این صورت، ویژگی‌هایی با مقیاس بزرگ‌تر می‌توانستند منجر به تسلط بر گردایان‌ها شده و مانع از یادگیری صحیح مدل شوند.

استانداردسازی به عنوان یکی از مراحل کلیدی پیش‌پردازش، نقش مهمی در بهبود همگرایی مدل و افزایش پایداری فرآیند آموزش ایفا کرد. همان‌طور که در بخش قبل اشاره شد، آموزش مستقیم مدل بر روی داده‌های خام به دلیل حجم بالای داده‌ها، وجود نویز و غیرایستا بودن سیگنال‌ها نمی‌تواند کارایی مطلوبی داشته باشد. برای رفع این محدودیت‌ها، مرحله استخراج ویژگی (Feature Extraction) انجام می‌شود تا اطلاعات کلیدی سیگنال در قالب مجموعه‌ای از شاخص‌های عددی خلاصه گردد. این شاخص‌ها قابلیت توصیف رفتار سیگنال در حوزه‌های مختلف را دارند و به مدل کمک می‌کنند تا الگوهای مرتبط با خارجی را بهتر تشخیص دهد.

در این پروژه ویژگی‌ها از سه نما (View) استخراج شده‌اند: حوزه زمان، حوزه فرکانس و حوزه زمان-فرکانس. برای هر نما، مجموعه‌ای از شاخص‌ها از سیگنال‌های ۶ حسگر شتاب‌سنچ محاسبه شده‌اند. در ادامه ساختار هر نما توضیح داده شده است..

ویژگی‌های حوزه زمان (Time-domain) در این بخش تعداد ۲۳ ویژگی برای هر کانال محاسبه شده است. با توجه به وجود ۶ کانال شتاب‌سنچ، در مجموع ۱۳۸ ویژگی زمانی (t_000 تا t_{137}) به دست آمده است. ترتیب ویژگی‌ها به گونه‌ای است که هر ۲۳ ویژگی متوالی به یک کانال تعلق دارند.

Code	Description
t_000	Mean
t_001	Standard Deviation
t_002	RMS
t_003	Kurtosis
t_004	Median
t_005	Minimum
t_006	Maximum (Peak)
t_007	Peak-to-Peak
t_008	Skewness
t_009	Crest Factor
t_010	Shape Factor
t_011	Smoothness Factor
t_012	Entropy
t_013	Zero Crossing Rate
t_014	Mean Absolute Deviation
t_015	Interquartile Range
t_016	Coefficient of Variation
t_017	Variance of Derivative
t_018	Number of Peaks
t_019	Maximum Absolute Deviation
t_020	Mean of Peaks
t_021	Hjorth Mobility
t_022	Hjorth Complexity

Table 1: Time domain features



ویژگی‌های حوزه فرکانس (**Frequency-domain**) برای هر کanal تعداد ۲۶ ویژگی در حوزه فرکانس محاسبه شده است. با وجود ۶ کanal شتاب‌سنج، در مجموع ۱۵۶ ویژگی فرکانسی (f_000 تا f_155) استخراج گردید. ترتیب مشابه حوزه زمان است؛ هر ۲۶ ویژگی متولی به یک کanal اختصاص دارد.

Code	Description
f_000	Amplitude FFT[1]
f_001	Amplitude FFT[2]
f_002	Amplitude FFT[3]
f_003	Amplitude FFT[4]
f_004	Amplitude FFT[5]
f_005	Maximum amplitude
f_006	Frequency variance
f_007	Frequency entropy
f_008	Spectral centroid
f_009	Spectral bandwidth
f_010	Spectral rolloff (85%)
f_011	Dominant frequency (Hz)
f_012	Dominant frequency amplitude
f_013	Harmonic mean of magnitudes
f_014	Spectral flatness
f_015	Spectral contrast
f_016	Spectral skewness
f_017	Spectral kurtosis
f_018	Low-band energy ratio
f_019	Mid-band energy ratio
f_020	High-band energy ratio
f_021	Spectral flux
f_022	Spectral slope
f_023	MFCC1 (if enabled)
f_024	MFCC2 (if enabled)
f_025	MFCC3 (if enabled)

Table 2: Frequency domain features

ویژگی‌های حوزه زمان-فرکانس (**Time-Frequency domain**) در این بخش ۱۰ ویژگی از روی طیف زمان-فرکانس برای هر کanal محاسبه گردید. با توجه به ۶ کanal شتاب‌سنج، تعداد کل ویژگی‌ها در این حوزه برابر با ۶۰ ویژگی (tf_000 تا tf_059) می‌باشد.

Code	Description
tf_000	Mean of spectrogram power
tf_001	Standard deviation
tf_002	Maximum
tf_003	Low/High energy ratio
tf_004	Spectral entropy
tf_005	Std across time axis
tf_006	Std across frequency axis
tf_007	Spectral flatness (geom/arith mean)
tf_008	Spectral slope (time axis)
tf_009	Top-3 peak energy ratio

Table 3: Time-Freq domain features

در مجموع، پس از پیش‌پردازش، تعداد ویژگی‌های استخراج شده به شرح زیر است: - ۱۳۸ ویژگی در حوزه زمان - ۱۵۶ ویژگی در حوزه فرکانس - ۶۰ ویژگی در حوزه زمان-فرکانس این ویژگی‌ها ورودی اصلی مدل‌های یادگیری ماشین در ادامه پروژه خواهند بود.

۳.۲ هدف اصلی پروژه و تغییر در پیاده‌سازی

هدف اصلی این پروژه بررسی و ارزیابی نمایهای مختلف سیگنال Time-Frequency و Frequency (Time) بر روی شبکه‌های یادگیری عمیق متفاوت بود. به طور مشخص، ایده اولیه بدین صورت تعریف شده بود:

- استفاده از ویژگی‌های حوزه زمان به عنوان ورودی شبکه LSTM به منظور بهره‌برداری از ماهیت توالی زمانی سیگنال‌ها. - به کارگیری ویژگی‌های حوزه فرکانس بر روی شبکه MLP به دلیل ماهیت برداری و عددی این نوع ویژگی‌ها. - استفاده از تصاویر حوزه زمان-فرکانس (Spectrogram) و Spectrogram به عنوان ورودی شبکه‌های عصبی کانولوشنی دو بعدی (2D CNN) به منظور تحلیل الگوهای تصویری و بافت‌های فرکانسی در طول زمان. با این حال، محدودیت‌های محاسباتی ناشی از حجم بالای داده‌ها و سنگینی فرآیند آموزش موجب بروز مشکلاتی شد. به طور خاص، اجرای این شبکه‌ها بر روی لپ‌تاپ شخصی و همچنین بستر Google Colab با محدودیت حافظه و توان پردازشی همراه بود. در بسیاری از موارد، فرآیند آموزش زمان بر بوده یا منجر به توقف ناگهانی سیستم (Crash) می‌شد.

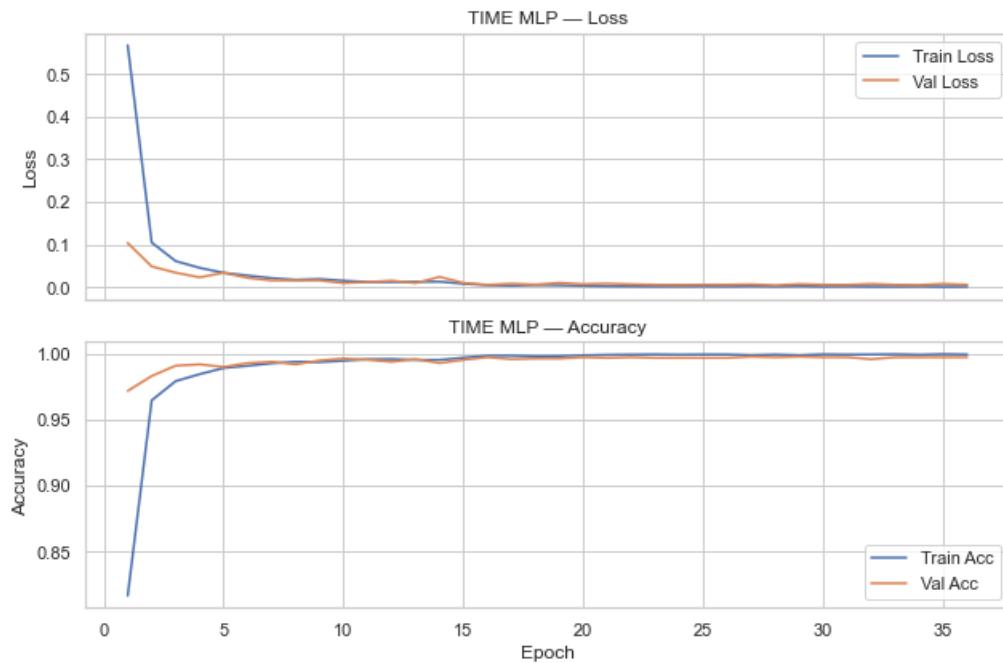
این چالش‌ها باعث گردید که رویکرد پروژه به سمت ساده‌سازی مدل‌ها تغییر یابد. در نهایت، تصمیم گرفته شد که برای ایجاد امکان مقایسه عادلانه و اجتناب از مشکلات محاسباتی، تمامی نمایهای بر روی یک معماری یکسان یعنی شبکه MLP آموزش داده شوند. این راهکار نه تنها محدودیت‌های سختافزاری را کاهش داد، بلکه شرایط یکسانی را برای تحلیل عملکرد نمایهای مختلف فراهم ساخت.

آزمایش اولیه با استفاده از تمام ویژگی‌ها

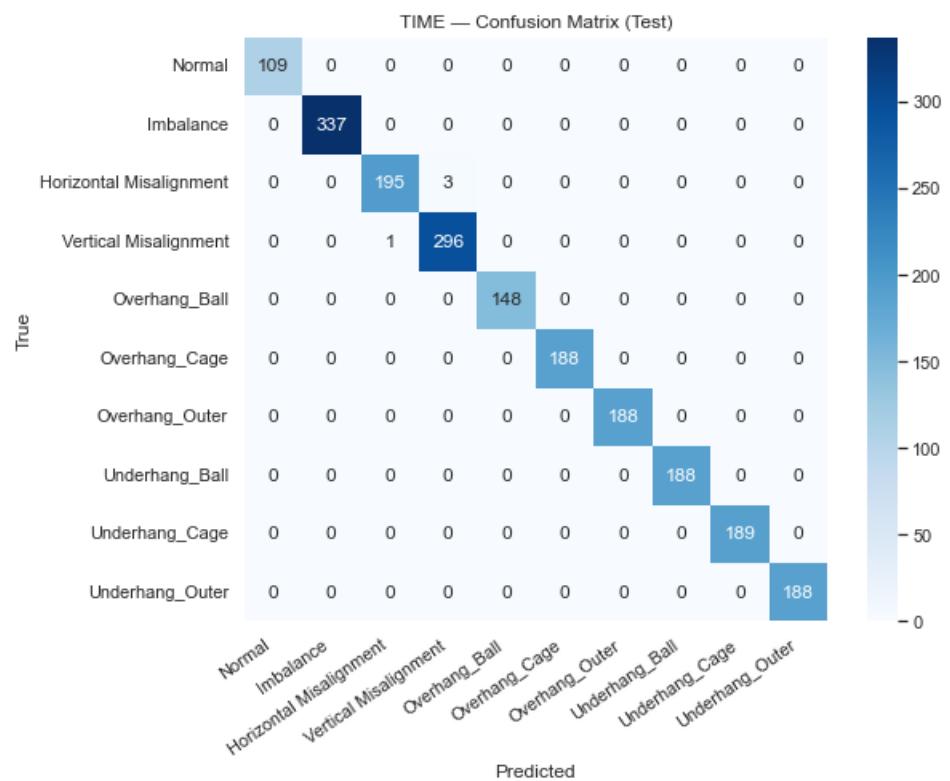
در ابتدا، با استفاده از رویکرد Hierarchical Classification و به کارگیری تمامی ویژگی‌های استخراج شده در یک حوزه، مدل‌ها توانستند به دقیقی نزدیک به ۱۰۰ درصد دست یابند. هرچند این نتیجه در نگاه اول مطلوب به نظر می‌رسد، اما از آنجا که هدف اصلی پروژه مقایسه و بررسی تفاوت عملکرد نمایهای مختلف بود، چنین شرایطی امکان تحلیل اثرات جداگانه هر بیو را فراهم نمی‌کرد.

به همین دلیل، برای ایجاد شرایط عادلانه‌تر و مشاهده تفاوت میان نمایهای، مجموعه داده اصلی با فواصل ۱۱ نمونه کاهش داده شد تا زیرمجموعه‌ای کوچکتر و چالش‌برانگیزتر ایجاد گردد. سپس مدل‌ها روی این زیرمجموعه‌ها آموزش داده شدند.

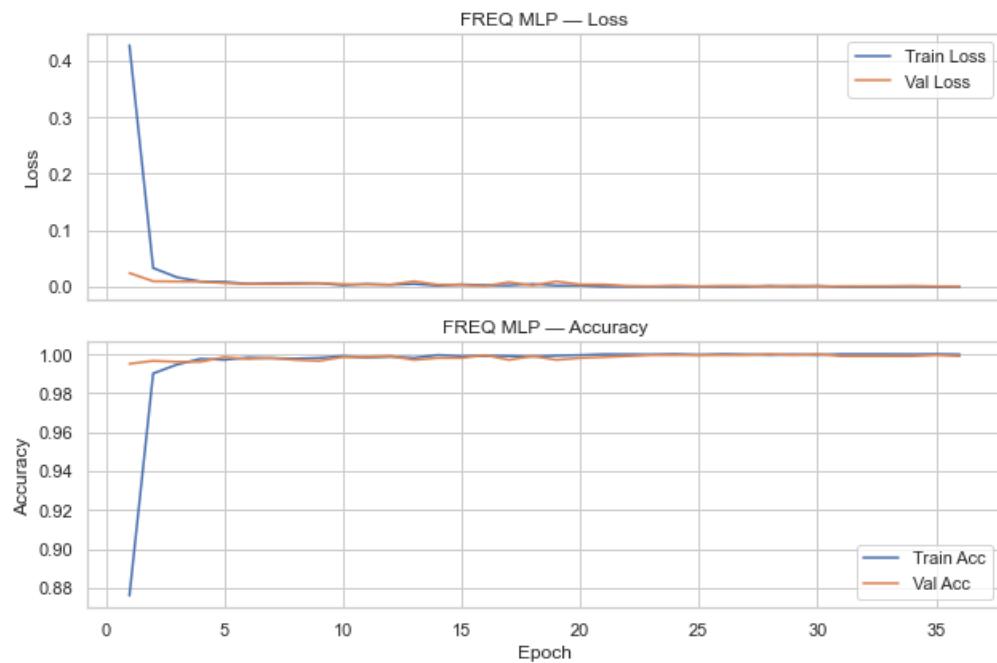
نکته قابل توجه این بود که حتی با استفاده از سه طبقه‌بند متفاوت و داده‌های کاهش‌یافته نیز همچنان دقت مدل‌ها نزدیک به ۱۰۰ درصد باقی ماند. این امر نشان می‌دهد که ویژگی‌های استخراج شده از سیگنال‌ها قدرت تفکیک بالایی دارند و به طور ذاتی اطلاعات کافی برای شناسایی خرابی‌ها را در خود جای داده‌اند. در شکل زیر نتایج این آزمایش‌ها مشاهده می‌شود:



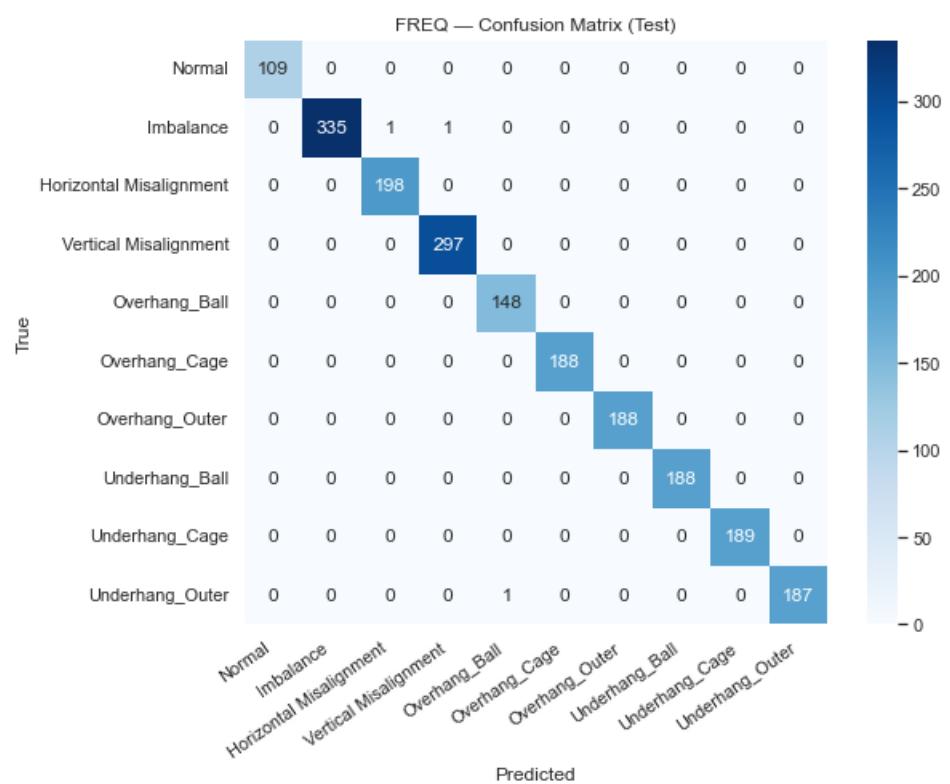
شکل ۴: نتایج آموزش اولیه با استفاده از تمام ویژگی‌ها در یک حوزه و زیرمجموعه‌های کاهش یافته داده



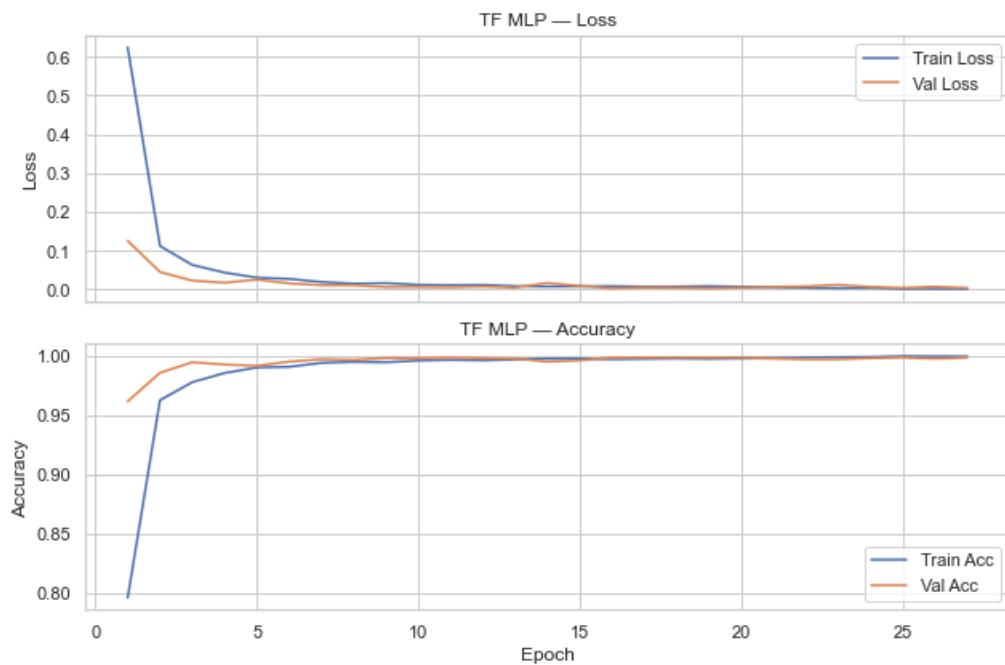
شکل ۵: نتایج آموزش اولیه با استفاده از تمام ویژگی‌ها در یک حوزه و زیرمجموعه‌های کاهش یافته داده



شکل ۶: نتایج آموزش اولیه با استفاده از تمام ویژگی‌ها در یک حوزه و زیرمجموعه‌های کاهش یافته داده



شکل ۷: نتایج آموزش اولیه با استفاده از تمام ویژگی‌ها در یک حوزه و زیرمجموعه‌های کاهش یافته داده



شکل ۸: نتایج آموزش اولیه با استفاده از تمام ویژگی‌ها در یک حوزه و زیرمجموعه‌های کاهش یافته داده



شکل ۹: نتایج آموزش اولیه با استفاده از تمام ویژگی‌ها در یک حوزه و زیرمجموعه‌های کاهش یافته داده



۴.۲ طراحی طبقه‌بند برای ده کلاس و انتخاب ویژگی‌ها

با توجه به اینکه نتایج آزمایش‌های اولیه حتی پس از کاهش حجم داده‌ها همچنان بسیار خوب و نزدیک به ۱۰۰ درصد بودند، تصمیم گرفتیم یک طبقه‌بند واحد طراحی کنیم که تمامی کلاس‌ها را به طور همزمان تشخیص دهد. این طبقه‌بند بر اساس ویژگی‌های استخراج شده برای هر ویو آموزش داده شد تا امکان مقایسه عملکرد نماهای مختلف Time–Frequency و Frequency را فراهم گردد.

در این پروژه، مسئله تشخیص خواری به صورت ده کلاسی تعریف شد. کلاس‌های در نظر گرفته شده به شرح زیر هستند:

- حالت سالم (Normal) - ناترازی افقی (Horizontal Misalignment) - ناترازی عمودی (Vertical Misalignment) - عدم تعادل (Underhang Outer Race Fault) - خطای قفسه یاتاقان زیرین (Underhang Cage Fault) - خطای مسیر بیرونی یاتاقان زیرین (Overhang Cage Fault) - خطای ساقمه یاتاقان زیرین (Underhang Ball Fault) - خطای قفسه یاتاقان رویی (Overhang Cage Fault) - خطای مسیر بیرونی یاتاقان رویی (Overhang Ball Fault) - خطای ساقمه یاتاقان رویی (Overhang Outer Race Fault)

برای شبیه‌سازی شرایطی که در آن مدل به تنها یک قادر به عملکرد بی‌نقص نباشد، از الگوریتم LightGBM برای رتبه‌بندی ویژگی‌ها استفاده شد. اهمیت هر ویژگی محاسبه گردید و ویژگی‌ها بر اساس میزان سهم آن‌ها در بهبود عملکرد مدل مرتب شدند.

سپس تنها تعدادی از ویژگی‌های برتر هر ویو انتخاب شدند و مدل‌ها بر روی این زیرمجموعه محدود آموزش داده شدند. این کار باعث شد شرایطی چالش‌برانگیزتر ایجاد شود تا تفاوت عملکرد بین نماها و همچنین نقش ویژگی‌های کلیدی در بهبود یا افت عملکرد مدل‌ها بهتر آشکار گردد.



۵.۲ تفاوت فیوژن در سطح ویژگی و فیوژن در سطح تصمیم

برای ترکیب نماهای مختلف سیگنال، دو رویکرد اصلی در نظر گرفته می‌شود: فیوژن در سطح ویژگی (Feature-level Fusion) و فیوژن در سطح تصمیم (Decision-level Fusion).

۱. فیوژن در سطح ویژگی (**Feature-level Fusion**) در این روش، ویژگی‌های استخراج شده از نماهای مختلف به صورت یک بردار واحد به هم متصل (Concatenate) می‌شوند و سپس یک مدل واحد بر روی این بردار آموزش داده می‌شود. - **مزایا:** - مدل می‌تواند ارتباطها ووابستگی‌های متقابل میان

ویژگی‌های نماهای مختلف را به طور مستقیم یاد بگیرد. - در شرایطی که داده کافی وجود داشته باشد، این روش می‌تواند منجر به بهبود دقیق شود. -

معایب: - ابعاد ورودی مدل بسیار بزرگ می‌شود و در نتیجه نیاز محاسباتی افزایش می‌یابد. - خطر بیشبرازش (Overfitting) به ویژه در داده‌های محدود بیشتر است. - حساسیت به نویز افزایش می‌یابد؛ زیرا تمام نماها هم‌زمان وارد مدل می‌شوند.

۲. فیوژن در سطح تصمیم (**Decision-level Fusion**) در این روش، برای هر ویو یک مدل جداگانه آموزش داده می‌شود. سپس در مرحله پیش‌بینی، خروجی مدل‌ها (به عنوان مثال احتمالات کلاس‌ها) ترکیب شده و پیش‌بینی نهایی صورت می‌گیرد. روش‌های متداول شامل میانگین‌گیری از احتمال‌ها، وزن دهنی بر اساس دقیقیت مدل‌ها یا رأی‌گیری اکثریت است. - **مزایا:** - انعطاف‌پذیری بالا؛ هر نما می‌تواند با معماری مخصوص به خود مدل‌سازی شود. -

پایداری بیشتر؛ اگر یک نما عملکرد ضعیفی داشته باشد، ترکیب نتایج سایر نماها می‌تواند ضعف آن را جبران کند. - نیاز به ابعاد ورودی بالا ندارد و آموزش هر مدل سبک‌تر است. - **معایب:** - مدل‌ها ارتباط‌های درونی بین ویژگی‌های نماهای مختلف را به طور مستقیم یاد نمی‌گیرند. - کیفیت نهایی ترکیب وابسته به روش فیوژن (میانگین ساده، وزن دهنی و غیره) است.

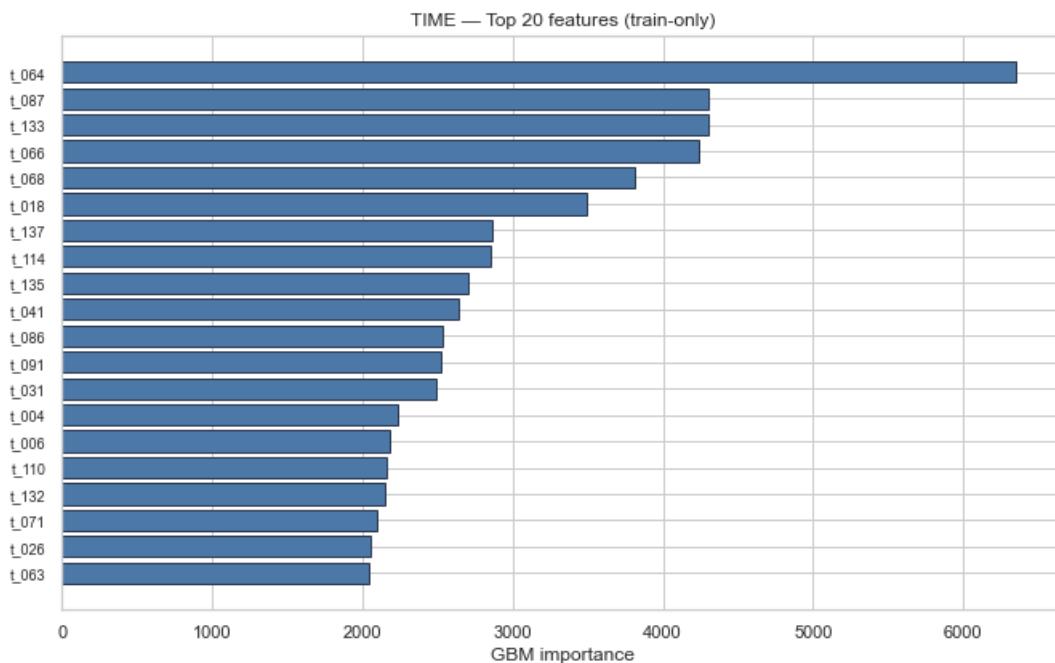
جمع‌بندی فیچر-فیوژن (Feature-level) مناسب زمانی است که داده کافی، توان محاسباتی بالا و نیاز به یادگیری تعاملات پیچیده بین نماها وجود دارد. در مقابل، دیسیژن-فیوژن (Decision-level) به دلیل سادگی، مقایسه‌بزیری و مقاومت در برابر خطای یک نما، در عمل کاربردی‌تر و پایدارتر است. در این پروژه، هر دو رویکرد بررسی شده‌اند و نتایج نشان داده‌اند که ترکیب در سطح تصمیم حتی با وجود کاهش ویژگی‌ها توانسته است دقیقی نزدیک به حالت ایده‌آل ایجاد کند.

آزمایش با چهار ویژگی برتر در هر ویو

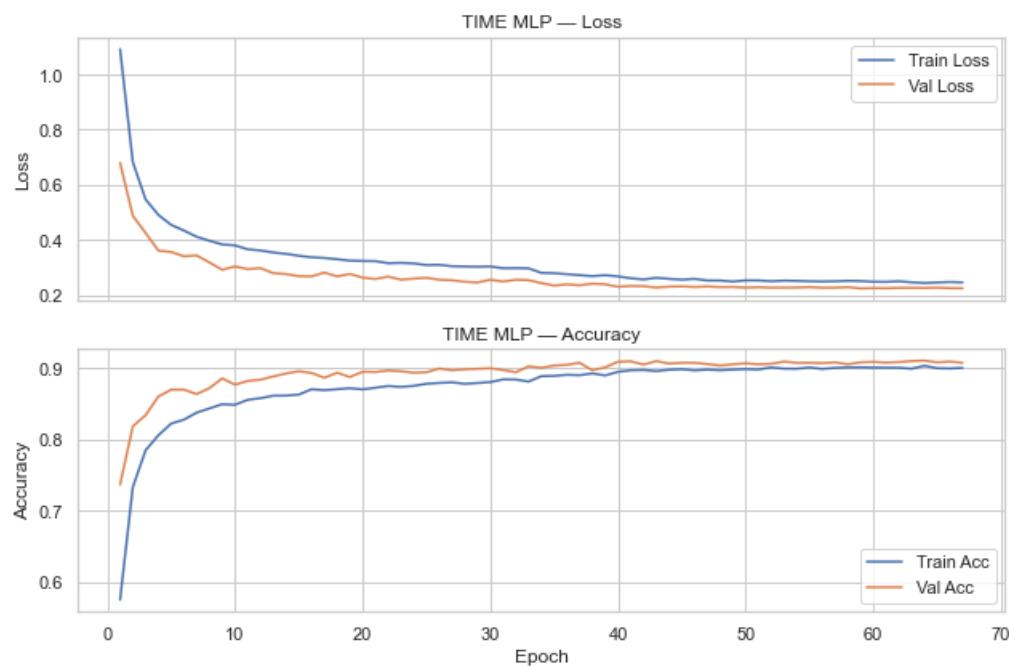
در این بخش، به منظور بررسی دقیق‌تر نقش نماهای مختلف، برای هر ویو یک مدل ده کلاسه آموزش داده شد. تفاوت اصلی این آزمایش با مراحل قبل در این بود که به جای استفاده از تمامی ویژگی‌ها، تنها چهار ویژگی برتر هر ویو (بر اساس رتبه‌بندی LightGBM) به عنوان ورودی مدل در نظر گرفته شدند. این محدودسازی آگاهانه به ما کمک می‌کند شرایطی چالش‌برانگیزتر ایجاد شود؛ شرایطی که در آن مدل نمی‌تواند صرفاً اتکا به حجم زیاد ویژگی‌ها عملکردی نزدیک به صدرصد داشته باشد. به این ترتیب، قدرت واقعی هر نما در استخراج الگوهای مرتبط با خرابی و نیز میزان اهمیت ویژگی‌های کلیدی بهتر نمایان می‌گردد.

برای مقایسه منصفانه، همه مدل‌ها به صورت ده کلاسه طراحی شدند تا تمامی کلاس‌های مسئله شامل حالت سالم، ناترازی‌ها، عدم تعادل و خرابی‌های یاتاقان زیرین و رویی را پوشش دهند.

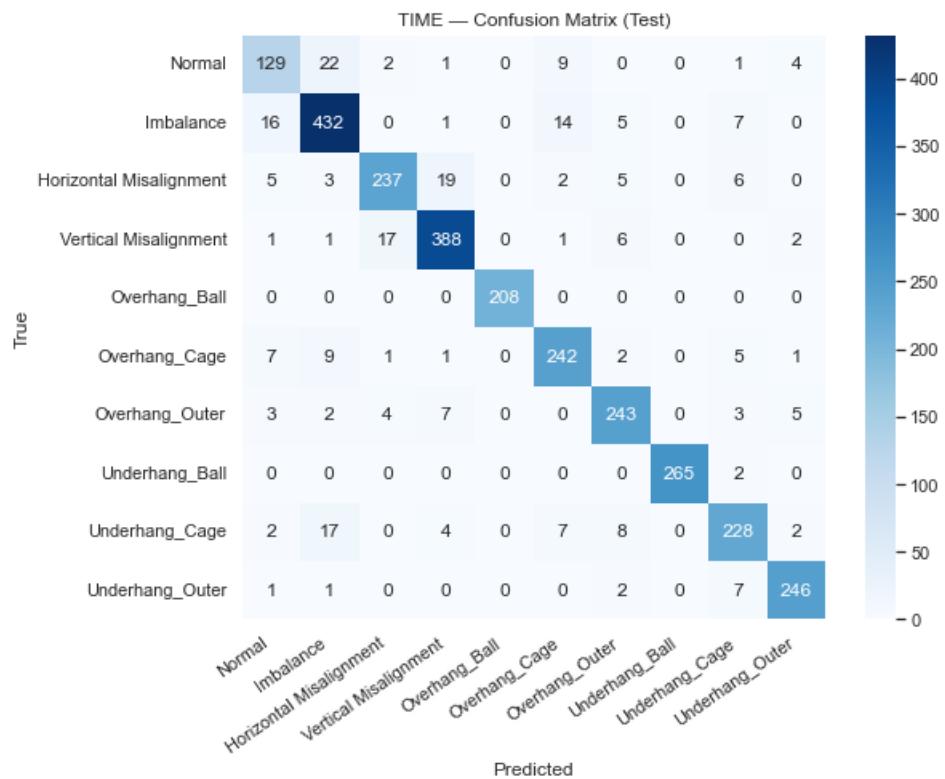
پس از آموزش مدل‌ها در نماهای مختلف، عملکرد تک‌تک آن‌ها مورد ارزیابی قرار گرفت. همچنین نتایج به دست آمده با رویکرد Decision Level Fusion مقایسه شدند. در این روش، خروجی مدل‌های مستقل هر ویو در سطح تصمیم‌گیری ترکیب می‌شود تا پیش‌بینی نهایی صورت گیرد. این مقایسه امکان بررسی مزایای استفاده از ترکیب نماها در مقابل مدل‌های تک‌نما را فراهم می‌سازد. نتایج به صورت زیر بودند:



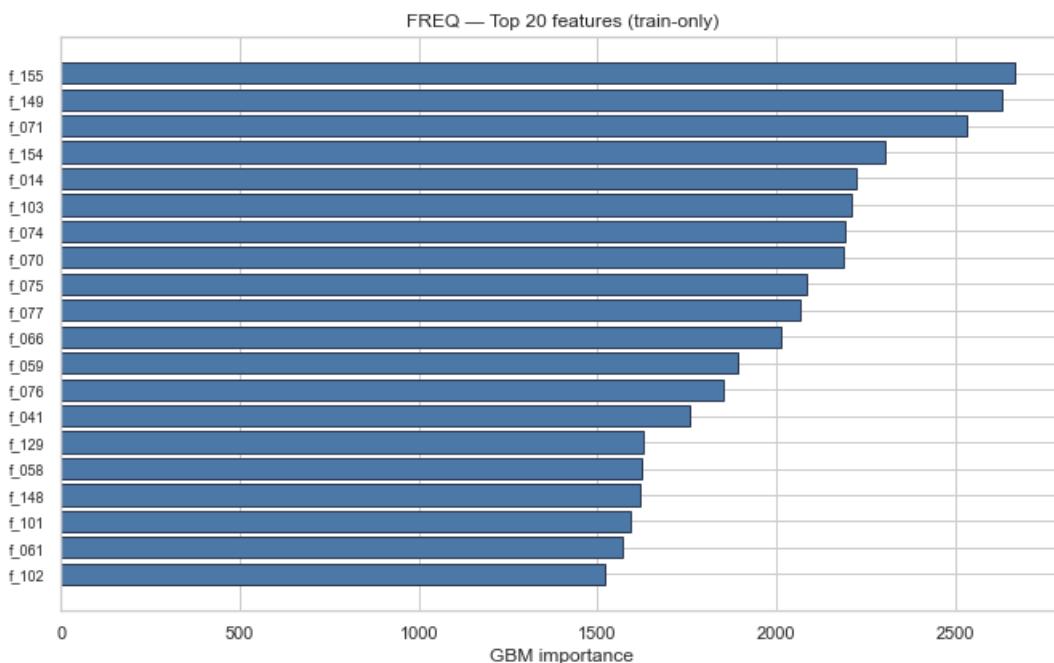
شکل ۱۰: ویژگی های برتر انتخاب شده در حوزه زمان بر اساس رتبه بندی LightGBM



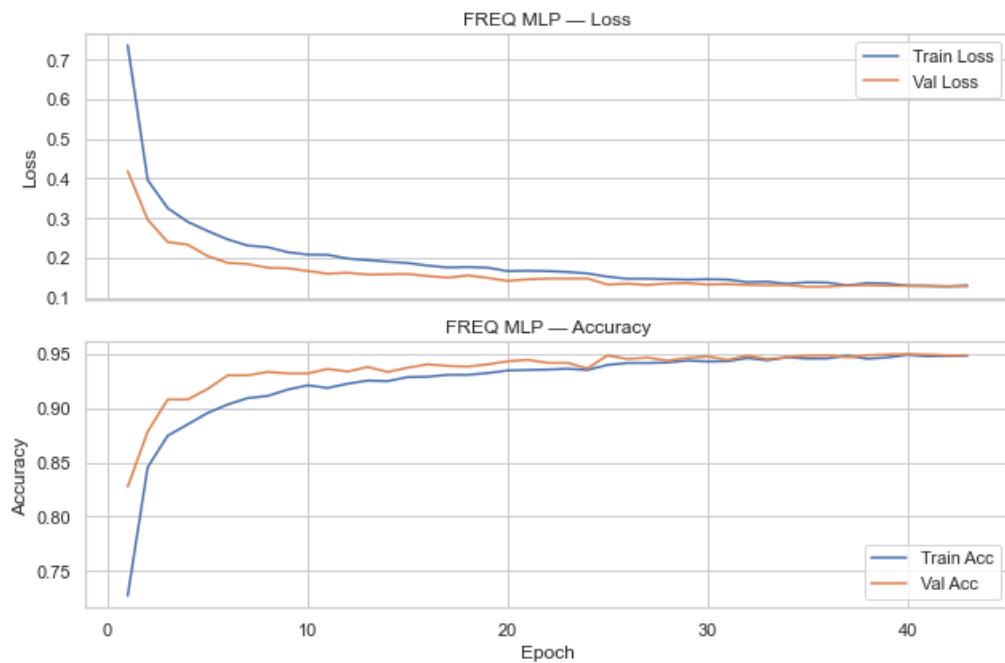
شکل ۱۱: نمودار تغییرات خطا و دقت مدل ده کلاسه بر روی ویو زمان با استفاده از چهار ویژگی برتر



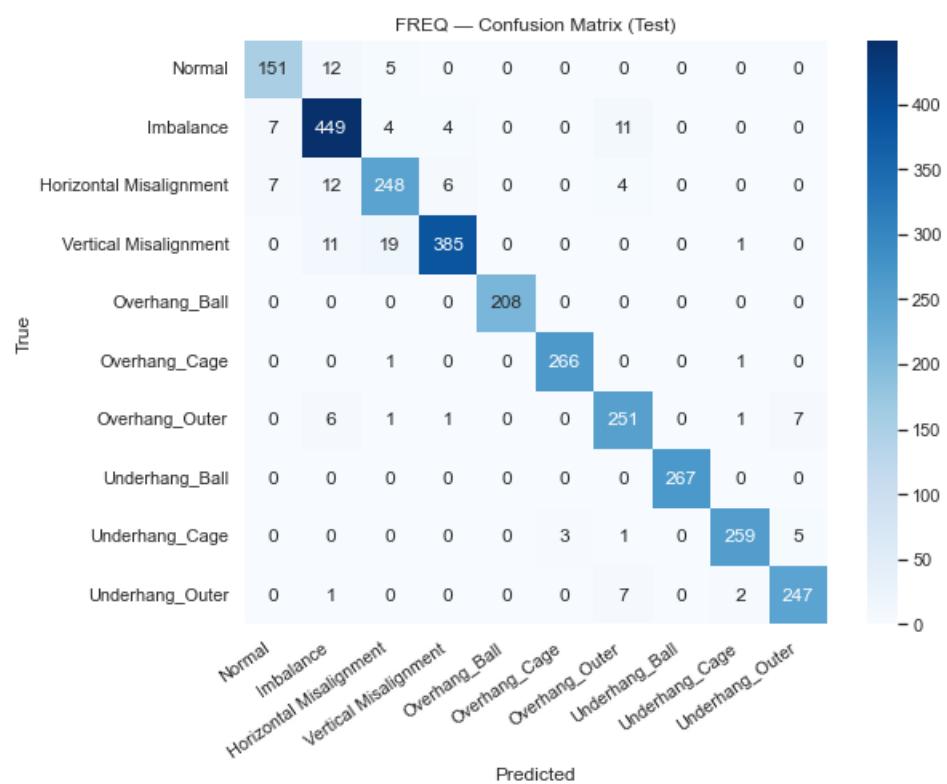
شکل ۱۲: ماتریس سردرگمی مربوط به ویو زمان با چهار ویژگی برتر



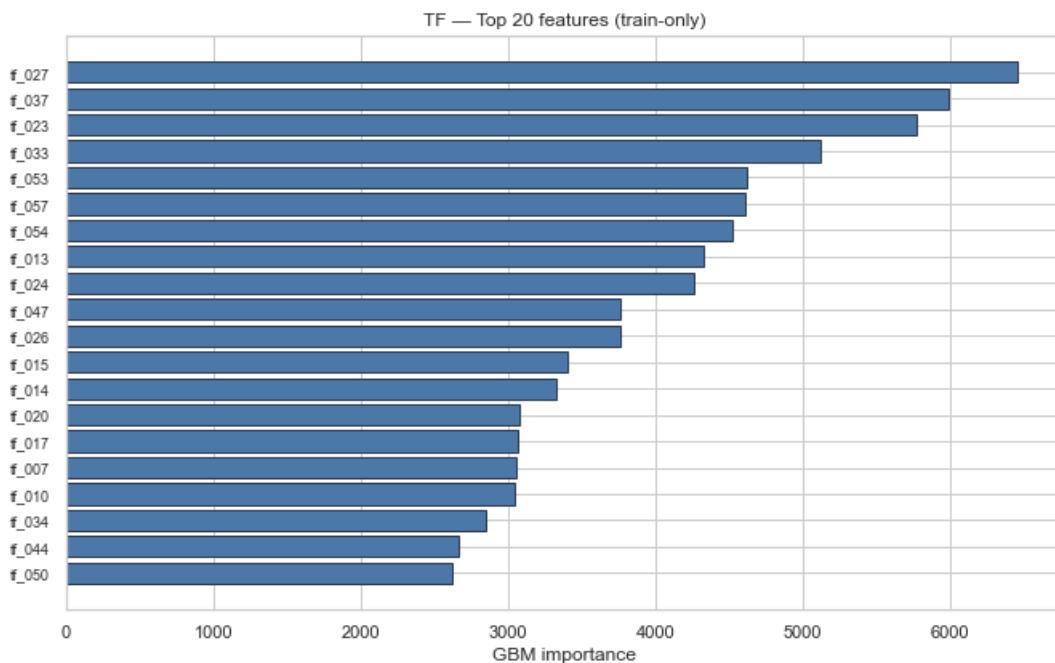
شکل ۱۳: ویژگی های برتر انتخاب شده در حوزه فرکانس بر اساس رتبه بندی LightGBM



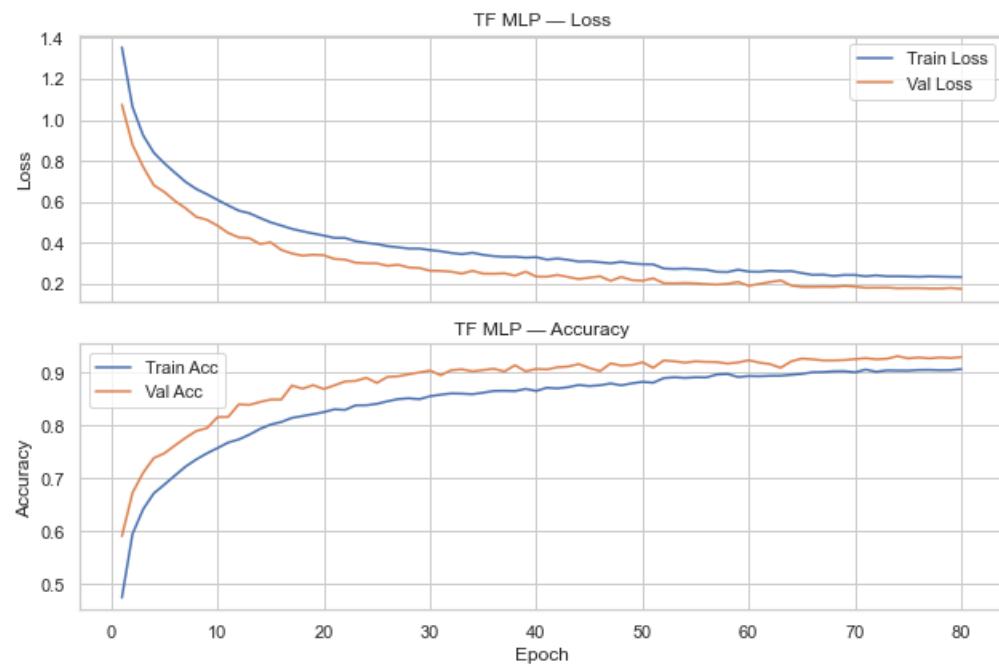
شکل ۱۴: نمودار تغییرات خطا و دقت مدل ده کلاسه بر روی ویو فرکانس با استفاده از چهار ویژگی بستر



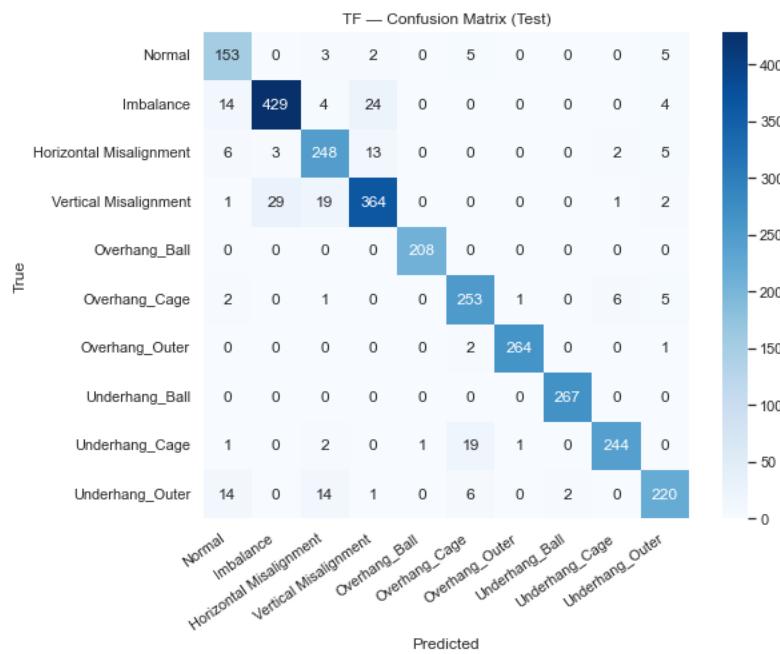
شکل ۱۵: ماتریس سردرگمی مربوط به ویو فرکانس با چهار ویژگی بستر



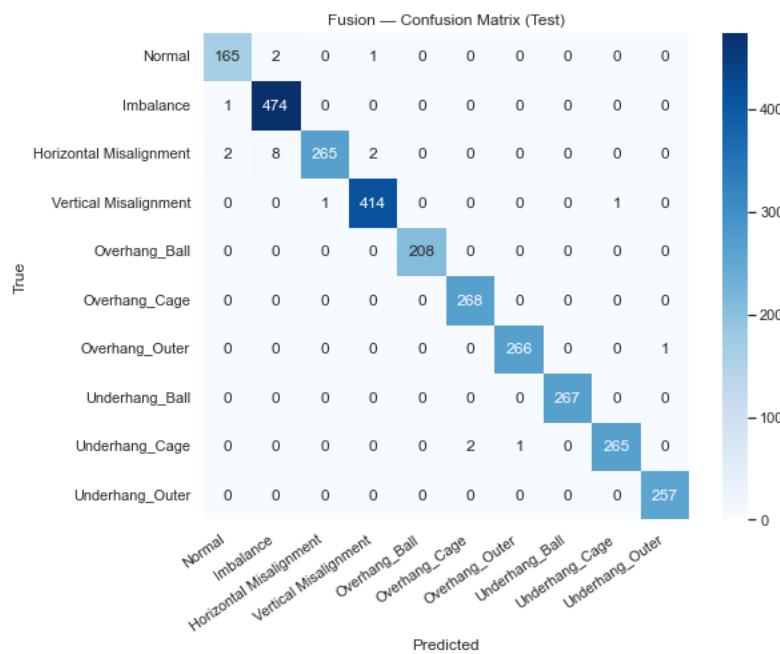
شکل ۱۶: ویژگی های برتر انتخاب شده در حوزه زمان‌افرکانس بر اساس رتبه‌بندی LightGBM



شکل ۱۷: نمودار تغییرات خطا و دقت مدل ده کلاسه بر روی ویو زمان‌افرکانس با استفاده از چهار ویژگی برتر



شکل ۱۸: ماتریس سردرگمی مربوط به ویو زمانی فرکانس با چهار ویژگی برتر



شکل ۱۹: ماتریس سردرگمی نهایی حاصل از ترکیب مدل ها در سطح تصمیم



```
[TIME] TEST acc=0.9119 macro-F1=0.9091
[FREQ] TEST acc=0.9512 macro-F1=0.9528
[TF] TEST acc=0.9230 macro-F1=0.9248

===== Decision-level Fusion (equal weights) =====
[FUSION] TEST acc=0.9923 macro-F1=0.9924
```

شکل ۲۰: دقت به تنهایی مدل‌ها و دقت مدل ترکیب شده

۶.۲ نتایج ارزیابی مدل‌ها

پس از آموزش مدل‌های ده کلاسه بر اساس چهار ویژگی بتر هر ویو، عملکرد آن‌ها بر روی داده‌های آزمون مورد بررسی قرار گرفت. نتایج نشان می‌دهند که هر ویو به تنهایی توانسته است به دقت و F1-score قابل توجهی دست یابد، اما ترکیب خروجی‌ها در سطح تصمیم‌گیری (Decision-level Fusion) موجب بهبود چشمگیر عملکرد کلی شده است.

نتایج به شرح زیر هستند:

- ویو زمان (Time): دقت آزمون برابر با 0.9119 و Macro-F1 برابر با 0.9091

- ویو فرکانس (Frequency): دقت آزمون برابر با 0.9512 و Macro-F1 برابر با 0.9528

- ویو زمان-فرکانس (Time-Frequency): دقت آزمون برابر با 0.9230 و Macro-F1 برابر با 0.9248

در نهایت، ترکیب نتایج سه مدل با وزن‌های مساوی در سطح تصمیم‌گیری منجر به دستیابی به بهترین عملکرد شد:

- فیوژن تصمیم‌ها (Decision-level Fusion): دقت آزمون برابر با 0.9923 و Macro-F1 برابر با 0.9924

این نتایج نشان می‌دهد که هرچند هر نما به تنهایی توانسته است عملکرد قابل قبولی ارائه دهد، اما ترکیب آن‌ها موجب بهبود چشمگیر دقت و افزایش قابلیت اطمینان در فرآیند تشخیص خطأ شده است.



نتایج با سه ویژگی برتر در هر ویو

در این آزمایش، تنها سه ویژگی برتر از هر ویو انتخاب و مدل‌های ده کلاسه آموزش داده شدند. نتایج نشان داد که کاهش بیشتر تعداد ویژگی‌ها باعث افت محسوس عملکرد مدل‌های تکنما شد.

- ویو زمان (Time): دقت آزمون برابر با 0.7144 و Macro-F1 برابر با 0.7171

- ویو فرکانس (Frequency): دقت آزمون برابر با 0.8325 و Macro-F1 برابر با 0.8313

- ویو زمان-فرکانس (Time-Frequency): دقت آزمون برابر با 0.7788 و Macro-F1 برابر با 0.7812

با این حال، ترکیب خروجی‌ها در سطح تصمیم‌گیری با وزن مساوی میان سه ویو، منجر به افزایش چشمگیر دقت و Macro-F1 شد:

- فیوژن تصمیم‌ها (Decision-level Fusion): دقت آزمون برابر با 0.9627 و Macro-F1 برابر با 0.9654

به منظور جلوگیری از تکرار نمودارهای پیشین، در این بخش تنها مقادیر دقت مدل‌های تکنما و مدل ترکیبی گزارش شده‌اند. همان‌طور که مشاهده می‌شود، حتی در شرایطی که عملکرد تکنماها افت کرده است، ترکیب آن‌ها توانسته به دقیقی نزدیک به نتایج ایده‌آل دست یابد.

```
[TIME] TEST acc=0.7144 macro-F1=0.7171
[FREQ] TEST acc=0.8325 macro-F1=0.8313
[TF] TEST acc=0.7788 macro-F1=0.7812

===== Decision-level Fusion (equal weights) =====
[FUSION] TEST acc=0.9627 macro-F1=0.9654
```

شکل ۲۱: دقت به تنها مدل‌ها و دقت مدل ترکیب شده



۷.۲ مقایسه نتایج فیوژن در سطح ویژگی و سطح تصمیم با ۳ ویژگی در هر نما

در این بخش نتایج دو رویکرد فیوژن در سطح ویژگی و سطح تصمیم گزارش و مقایسه شده‌اند. همان‌طور که مشاهده می‌شود، هر دو روش عملکرد مناسبی داشته‌اند، اما تفاوت معناداری میان آن‌ها دیده می‌شود.

- فیوژن در سطح ویژگی (Feature-level Fusion): دقت آزمون برابر با ۰.۹۹۶۹ Macro-F1 برابر با ۰.۹۹۶۶ - فیوژن در سطح تصمیم

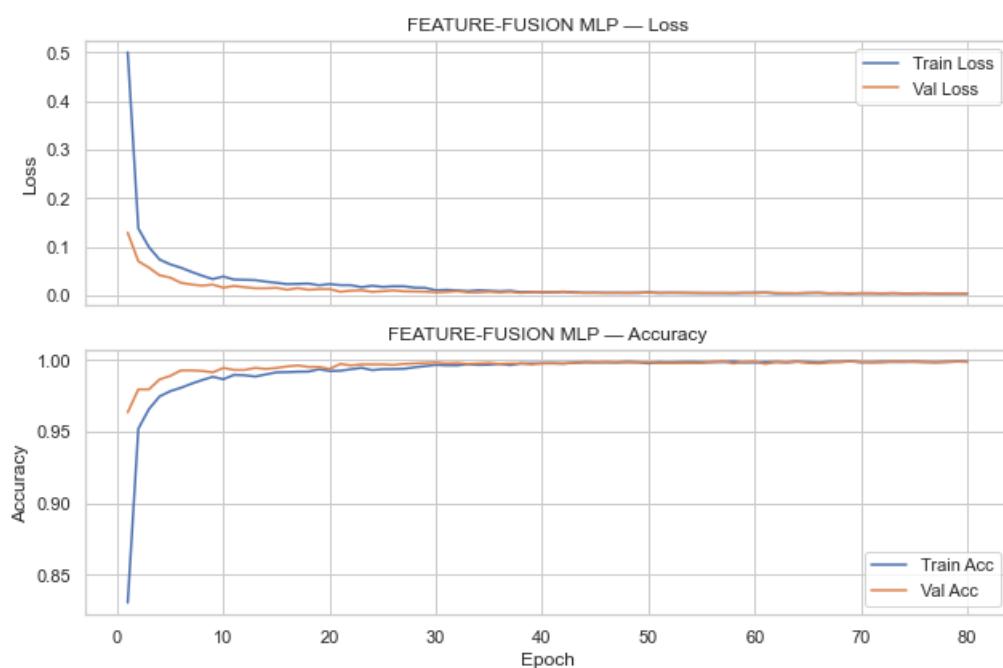
- (Decision-level Fusion): دقت آزمون برابر با ۰.۹۶۲۷ Macro-F1 برابر با ۰.۹۶۵۴

این نتایج نشان می‌دهد که فیوژن در سطح ویژگی توانسته است با استفاده همزمان از فیچرهای انتخاب شده از تمامی نماها، ارتباط‌های متقابل میان داده‌ها را بهتر مدل کرده و در نهایت به عملکردی تقریباً بی‌نقص دست یابد. در مقابل، فیوژن در سطح تصمیم هرچند نسبت به مدل‌های تکنما بهبود قابل توجهی ایجاد کرده است، اما به دلیل ترکیب خروجی‌ها در مرحله نهایی، نتوانسته به همان سطح دقت فیوژن در سطح ویژگی برسد.

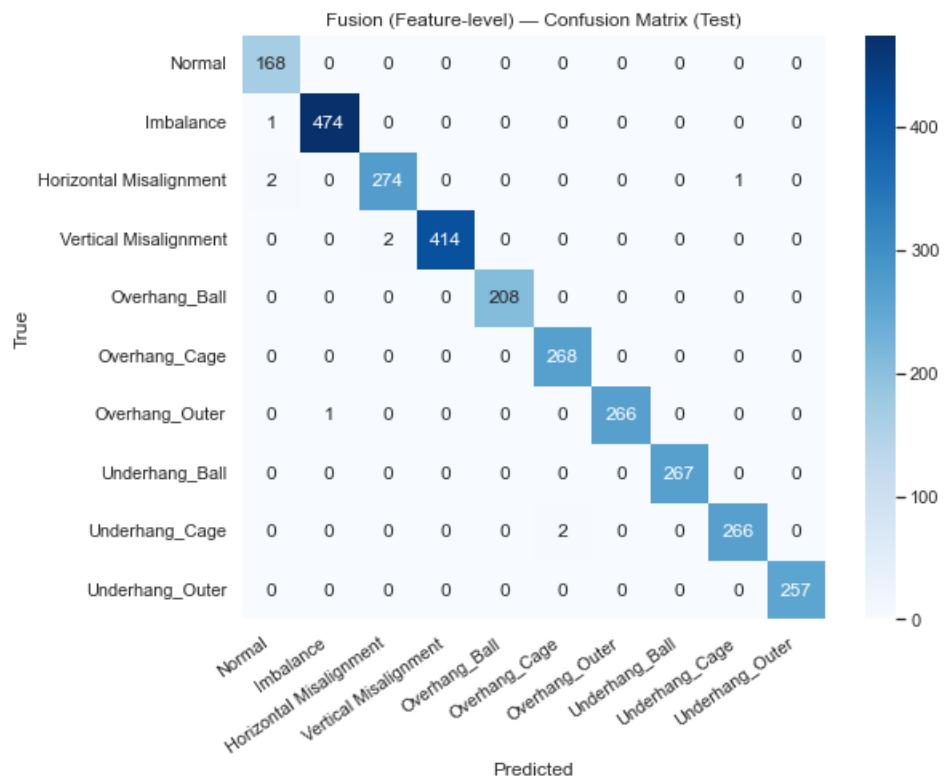
به طور کلی، می‌توان نتیجه گرفت که در شرایطی که داده کافی و توان محاسباتی مناسب وجود دارد، فیوژن در سطح ویژگی می‌تواند نتایج بهتری به همراه

داشته باشد؛ در حالی که فیوژن در سطح تصمیم با وجود سادگی و پایداری بیشتر، همچنان گزینه‌ای ارزشمند در شرایط محدودیت منابع محسوب می‌شود.

در ادامه تعدادی از نتایج و نمودارها نمایش داده شده‌اند:



شکل ۲۲: نمودار تغییرات خطای دقت در فیوژن سطح ویژگی با ۳ ویژگی در هر نما (Feature-level Fusion)



شکل ۲۳: ماتریس سردرگمی حاصل از فیوژن در سطح ویژگی

```
[FUSION/Feature] TEST acc=0.9969 macro-F1=0.9966
=====
===== Decision-level Fusion (equal weights) =====
[FUSION] TEST acc=0.9627 macro-F1=0.9654
```

شکل ۲۴: مقایسه عملکرد فیوژن در سطح ویژگی و سطح تصمیم از نظر دقت و Macro-F1

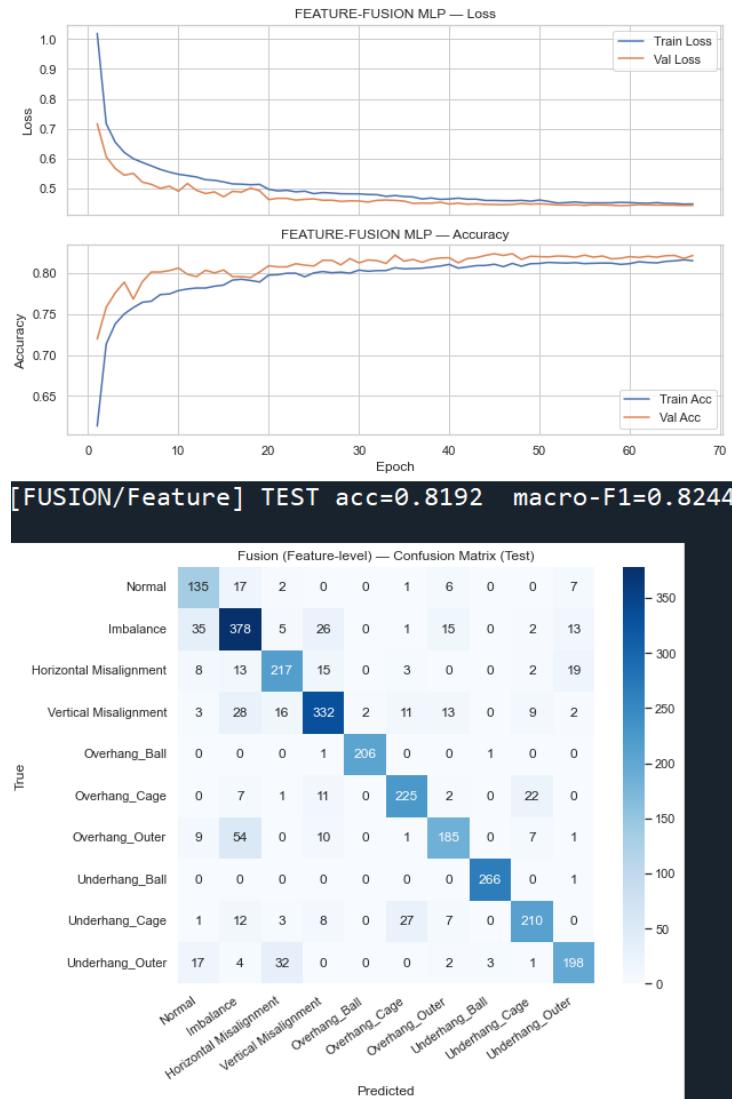


۸.۲ نتایج فیوژن در سطح ویژگی با دو فیچر در هر ویو

در این آزمایش، تنها دو ویژگی برتر از هر ویو انتخاب و با هم ترکیب شدند تا شرایط سخت‌تری برای مدل‌سازی ایجاد گردد. هدف از این کار بررسی توانایی فیوژن در سطح ویژگی (Feature-level Fusion) در شرایطی است که اطلاعات ورودی محدود است و مدل باید با داده‌های کمتر به تفکیک کلاس‌ها بپردازد.

نتایج به دست آمده نشان می‌دهند که اگرچه دقت و Macro-F1 نسبت به حالتی که تعداد بیشتری فیچر استفاده شده بود کاهش یافته است، اما مدل همچنان توانسته است عملکرد قابل قبولی ارائه دهد و بخش قابل توجهی از کلاس‌ها را با دقت مناسبی تشخیص دهد.

- دقت آزمون: 0.8192 - Macro-F1: 0.8244



شکل ۲۵: خطای ماتریس در هم‌ریختگی و دقت فیچر فیوژن با ۲ ویو در نما و جمعاً ۶ ویژگی

این نتایج نشان می‌دهند که حتی با تعداد محدودی از ویژگی‌ها نیز فیوژن در سطح ویژگی می‌تواند توانایی خود را در استخراج الگوهای معنادار حفظ کند. هرچند کاهش تعداد فیچرها باعث افت دقت کلی شده است، اما همچنان مدل قادر به شناسایی صحیح اکثر کلاس‌ها بوده و نشان می‌دهد که فیچرهای کلیدی انتخاب شده توسط LightGBM حاوی اطلاعات ارزشمندی هستند.



۹.۲ نمای صدا و نقش آن در تشخیص خطا

علاوه بر داده‌های ارتعاشی، در مجموعه داده MaFaulDa سیگنال صوتی ثبت شده توسط میکروفون نیز وجود دارد. این نما (Audio View) می‌تواند منبع ارزشمندی از اطلاعات مکمل برای تشخیص خطا در یاتاقان‌ها باشد، زیرا برخی الگوهای خرابی نه تنها در ارتعاشات مکانیکی بلکه در طیف فرکانسی صدای تولید شده نیز ظاهر می‌شوند.

سیگنال‌های صوتی معمولاً حاوی مؤلفه‌های فرکانسی مشخصی هستند که با بروز ناهنجاری در سیستم تغییر می‌کنند. برای مثال، ضربه‌های ناشی از آسیب به ساقمه یا قفسه یاتاقان می‌توانند الگوهای تناوبی خاصی در حوزه فرکانس ایجاد کنند. همچنین تغییرات دینامیک ناشی از ناترازی یا عدم تعادل در دستگاه اغلب منجر به تغییر در شدت یا توزیع انرژی صوتی می‌شود.

برای استفاده از داده‌های صوتی در تشخیص خطا، روش‌های مختلفی وجود دارد:

- **تحلیل فرکانسی:** با استفاده از تبدیل فوریه (FFT) می‌توان اجزای فرکانسی صدای تولید شده را بررسی کرد و تغییرات ناشی از خرابی را در باندهای مختلف شناسایی نمود.

- **تحلیل زمان-فرکانس:** روش‌هایی مانند Spectrogram با امکان نمایش سیگنال صوتی در هر دو بعد زمان و فرکانس را فراهم می‌کنند. این نمایش تصویری می‌تواند برای مدل‌های یادگیری عمیق دو بعدی (2D CNN) بسیار مناسب باشد، زیرا الگوهای بصری ایجاد شده از صدای سالم و معیوب تفاوت‌های قابل توجهی خواهد داشت.

- **ویژگی‌های آکوستیکی:** ساختهای مانند ضرایب MFCC، Spectral Entropy، Spectral Centroid و Spectral Flatness می‌توانند به عنوان ویژگی‌های عددی استخراج و در طبقه‌بندی‌های کلاسیک یا شبکه‌های عصبی چندلایه (MLP) مورد استفاده قرار گیرند. در مجموع، نمای صوتی ظرفیت بالایی برای تکمیل نماهای ارتعاشی دارد. ترکیب این نما با داده‌های دیگر می‌تواند به بهبود دقت تشخیص خرابی کمک کند. بهویژه در شرایطی که حسگرهای ارتعاشی اطلاعات کافی فراهم نمی‌کنند یا نویز بالایی دارند. به همین دلیل، استفاده از روش‌های مبتنی بر یادگیری عمیق دو بعدی و تحلیل‌های فرکانسی و زمانی فرکانسی بر روی داده‌های صوتی می‌تواند افکاری جدیدی در زمینه پایش وضعیت و تشخیص خطای یاتاقان‌ها ایجاد نماید.

شبیه سازی و نتایج

برای ارزیابی نقش میکروفون در تشخیص خطای یک مدل MLP تنها بر اساس ویژگی‌های صوتی آموزش داده شد نتایج نشان می‌دهد که کارایی برای استفاده مستقیم به اندازه نماهای ارتعاشی مناسب نیست دقت آزمون برابر با 0.6576 و Macro F1 برابر با 0.4990 به دست آمد این الگو بیانگر حساسیت بالا به نویز محیط و تغییرات عملیاتی است و همچنین نشان می‌دهد که الگوهای کلیدی خرابی در نمای صدا نیازمند نمایش های غنی تر از raw features عددی هستند



شکل ۲۶: روند Loss و Accuracy برای آموزش مدل مبتنی بر نمای صدا

بحث و کاربردهای مناسب نمای صدا

با وجود کارایی محدود در MLP تک نما نمای صدا می تواند در طراحی های پیشرفته مفید باشد نمایش های زمان فرکانس مانند Spectrogram و Scalogram ورودی مناسبی برای 2D CNN یا مدل های CRNN هستند و امکان استخراج بافت های زمانی فرکانسی مرتبط با ضربه های خرابی را فراهم می کنند ویژگی های آکوستیکی همچون MFCC و Spectral Centroid و Spectral Entropy و Spectral Flatness نیز می توانند در ترکیب با نمایهای ارتعاشی به بهبود تشخیص کمک کنند در چیدمان های چند میکروفونه با آرایش های مختلف استفاده از مفاهیم مکانی مانند اختلاف زمانی و اختلاف سطح بین کanal ها ITD ILD هموارسازی فضایی و Beamforming و روش های همبستگی GCC PHAT می توانند نسبت سیگنال به نویز را بهبود دهد و الگوهای منبع صوتی مرتبط با خرابی را برجسته کند در چنین ساختارهایی نمای صدا به عنوان مکمل نمایهای ارتعاشی نقش پررنگ تری خواهد داشت و فیوژن در سطح تصمیم یا ویژگی می تواند مزیت قابل توجهی ایجاد کند.



۱۰.۲ کاربرد داده‌های چند میکروفونه در تشخیص خطا

در مجموعه داده MaFaulDa که مبنای این پروژه قرار گرفت، تنها یک سیگنال صوتی از یک میکروفون در دسترس بود. بنابراین امکان بهره‌گیری از قابلیت‌های چند میکروفونه و تحلیل فضایی سیگنال‌ها وجود نداشت. با این حال، در پژوهش‌های دیگر از آرایش‌های چند میکروفونه استفاده شده است و نتایج آن‌ها نشان می‌دهد که داده‌های صوتی در صورت پردازش صحیح می‌توانند ابزاری مؤثر و قابل اتکا برای تشخیص خطاهاست یاتاقان باشند. استفاده از چند میکروفون در جهات مختلف این امکان را فراهم می‌سازد که اطلاعات مکانی و فضایی سیگنال نیز به دست آید. این امر علاوه بر افزایش نسبت سیگنال به نویز (SNR)، امکان جداسازی بهتر منابع صوتی و برجسته‌سازی الگوهای مربوط به خرابی را فراهم می‌کند. روش‌هایی مانند Beamforming و محسوب می‌شوند. همچنین ترکیب داده‌های چند میکروفونه با تحلیل‌های زمان–فرکانس (Scalogram و Spectrogram) و ویژگی‌های آکوستیکی (از جمله MFCC 2D Spectral Entropy، Spectral Centroid و شبکه‌های بازگشتی–کانولوشنی (CRNN) ایجاد می‌کند.

شکل زیر نمونه‌ای از یک مطالعه مبتنی بر داده‌های چند میکروفونه را نشان می‌دهد که در آن آرایش میکروفون‌ها به گونه‌ای طراحی شده است که اطلاعات فضایی برای بهبود فرآیند تشخیص خرابی مورد استفاده قرار گیرد:

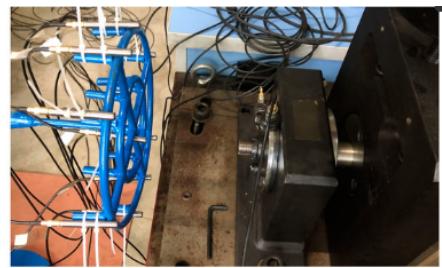


Figure 5. Experimental setup.

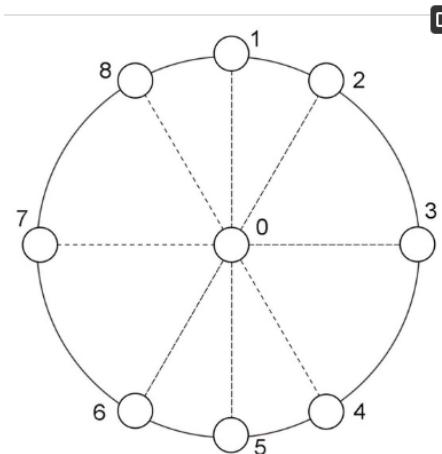


Figure 6. Microphone arrangement.

شکل ۲۷: نمونه‌ای از به کارگیری داده‌های چند میکروفونه در تشخیص خطاهاست یاتاقان

این نتایج بیانگر آن است که هر چند دیتابست ما فاقد چنین قابلیتی بود، اما استفاده از چند میکروفون می‌تواند دقیق و پایداری روش‌های تشخیص خطا را به طور چشمگیری افزایش دهد و به عنوان مسیری ارزشمند برای پژوهش‌های آینده مطرح شود.



۱۱.۲ ویژگی‌های آکوستیکی مهم در تشخیص خطا تبیین و مصورسازی

برای تحلیل نقش نمای صدا در تشخیص خرابی یاتاقان مجموعه‌ای از ویژگی‌های آکوستیکی استخراج و با LightGBM رتبه بندی شد نمودار اهمیت ده ویژگی برتر در شکل 28 نمایش داده شده است در ادامه چند ویژگی شاخص را معرفی و چرایی اثرگذاری آن‌ها را توضیح می‌دهیم

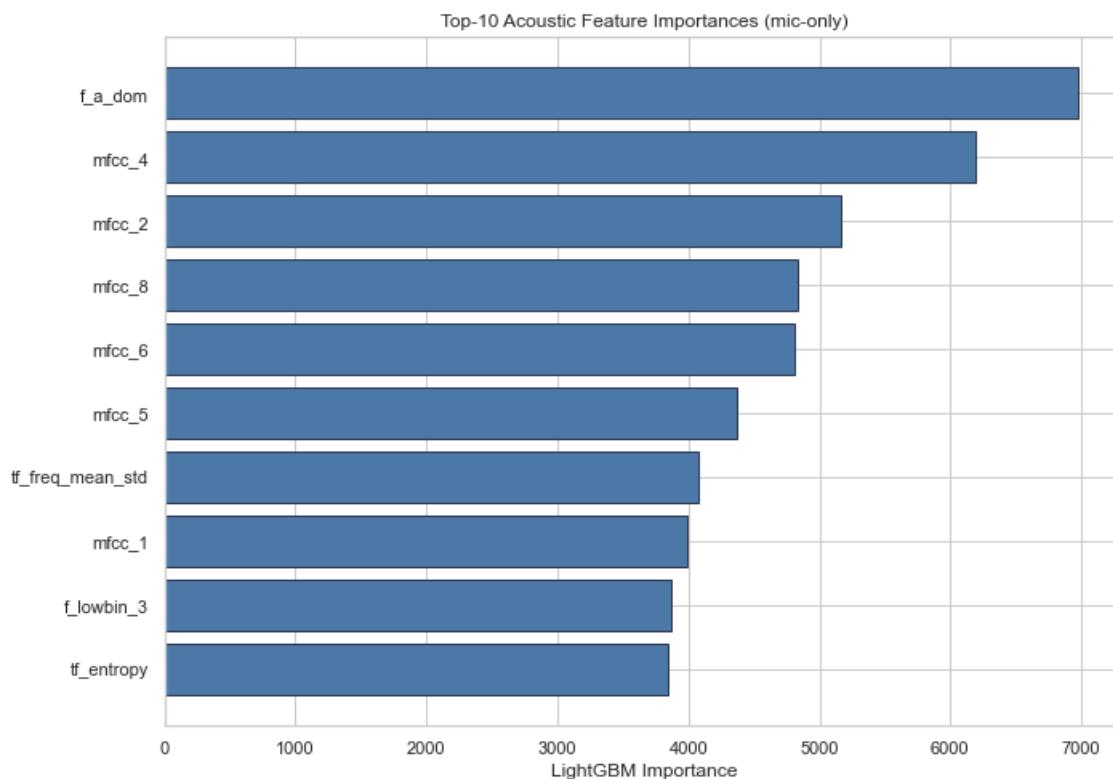
f_a_dom دامنه فرکانس غالب وجود یک مولفه توナル پرقرت در طیف شاخصی از پدیده‌های مکانیکی تکرارشونده مانند سوت یاتاقان و یا اقلام چرخان نامتعادن است افزایش دامنه در این مولفه اغلب با تشدید و یا بروز عیوب تنابوی همبستگی دارد

MFCC‌های مرتبه پایین تا میانی مانند **mfcc_1** و **mfcc_2** و **mfcc_4** و **mfcc_5** و **mfcc_6** و **mfcc_8** ضرایب MFCC شکل پاکت طیفی را در مقیاس Mel خلاصه می‌کنند و نسبت به تغییر سطح کلی صدا مقاوم ترند این ضرایب به تغییرات بافت طیفی ناشی از ضربه‌ها و زبری سطح حساس‌اند و در بسیاری از سامانه‌های تشخیص آکوستیکی به عنوان ویژگی‌های استاندارد به کار می‌روند

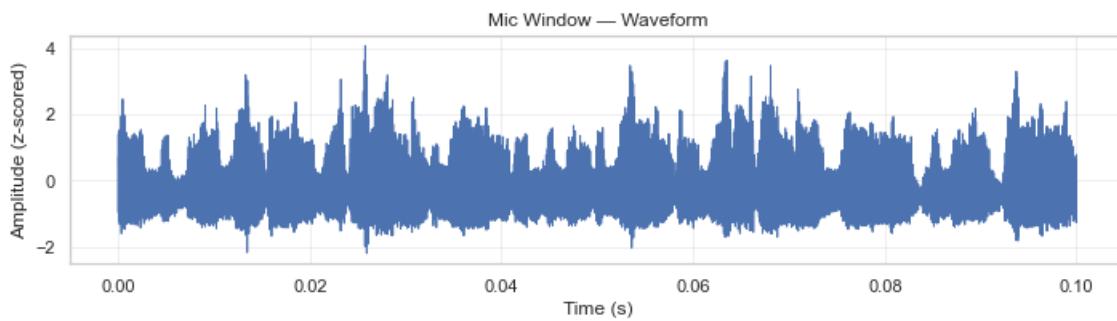
tf_lowbin_3 انحراف معیار فرکانس غالب در طول زمان این ویژگی ناپایداری فرکانس غالب را در امتداد زمان می‌سنجد سیگنال‌های ناشی از خرابی‌های گذرا معمولاً تغییرپذیری زمانی بیشتری دارند و مقدار این شاخص را افزایش می‌دهند

tf_entropy آنتروپی طیفی زمان فرکانس آنتروپی بالاتر نشانگر پراکندگی انرژی در باندهای متعدد و رفتار نویزی تر است در مقابل آنتروپی پایین تر معمولاً به وجود مولفه‌های توナル قوی و ساختارمند اشاره دارد

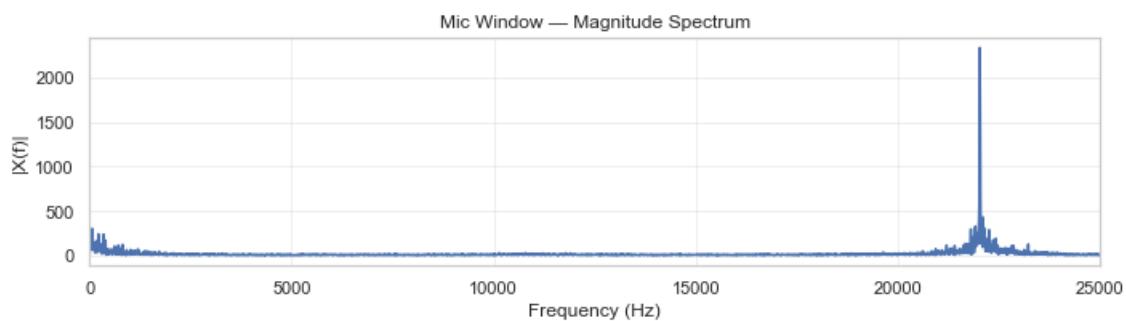
شکل‌های زیر نمایه‌ای مکمل از همان پنجره صوتی را نشان می‌دهند و دلیل مفید بودن ویژگی‌های فوق را روشن تر می‌کنند



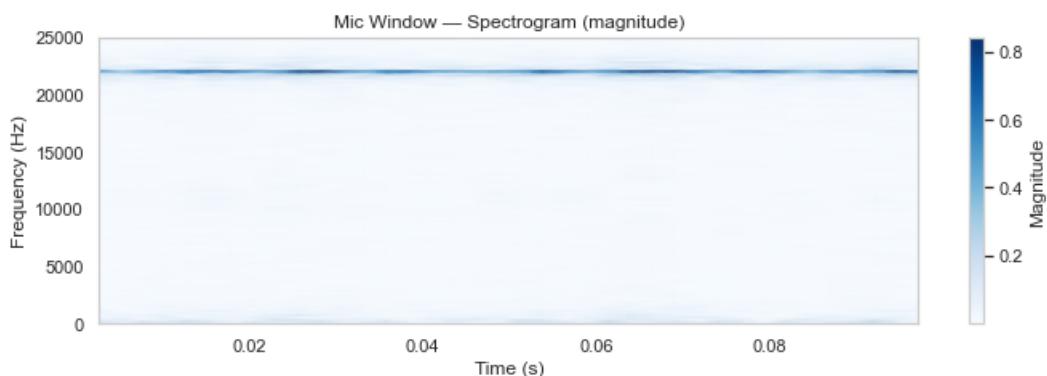
شکل ۲۸: ده ویژگی آکوستیکی برتر بر اساس اهمیت LightGBM نمای میکروفون



شکل ۲۹: شکل موج پنجه صوتی نوسانات دامنه و ضربه ها در حوزه زمان که پایه استخراج ویژگی های زمانی مانند نرخ عبور از صفر و شمار قله ها هستند



شکل ۳۰: طیف دامنه حضور قله توانal پرقدرت در ناحیه فرکانسی بالا که با شاخص f_a_{dom} سنجیده می شود و گواه رفتار تنابی سوت یا تشدد



شکل ۳۱: اسپکتروگرام ریابی همزمان زمان و فرکانس باندهای پایدار توانال و لکه های انرژی گذرا که مبنای ویژگی های زمان فرکانس مانند $tf_entropy$ و $tf_freq_mean_std$ هستند



تعریف فشرده برخی شاخص ها

Spectral Centroid

$$SC = \frac{\sum_{i=1}^N f_i \cdot |X(f_i)|}{\sum_{i=1}^N |X(f_i)|}$$

Spectral Entropy

$$SE = -\frac{1}{\log N} \sum_{i=1}^N p_i \log p_i \quad \text{که در آن} \quad p_i = \frac{|X(f_i)|}{\sum_{j=1}^N |X(f_j)|}$$

$$c_k = \sum_{m=1}^M \log(E_m) \cdot \cos\left(\frac{\pi k}{M} \left(m - \frac{1}{2}\right)\right), \quad k = 1, 2, \dots, K$$

(MFCC via DCT of log-mel energies)

جمع بندی کاربردی

مجموعه ویژگی های آکوستیکی منتخب تصویری مکمل از وضعیت سامانه فراهم می کنند قله توانال غالب و انرژی باندهای پایین سرنخ هایی از سوت و ضربه های مکانیکی می دهند ضرایب MFCC تغییرات بافت طیفی و زبری را به خوبی خلاصه می کنند و شاخص های زمان فرکانس ناپایداری و پراکندگی انرژی را کمی سازی می کنند بدین ترتیب حتی هنگامی که آموزش مستقیم MLP بر داده صوتی به دقت مطلوب نمی رسد بهره گیری هدفمند از این ویژگی ها در کنار نماهای ارتعاشی و یا در معماری های دوبعدی مانند CNN 2D و CRNN می تواند نقش تعیین کننده ای در بهبود تشخیص خطای داشته باشد



۱۲.۲ جمع‌بندی و نتیجه‌گیری

- در این پژوهش، مسئله تشخیص خرابی یاتاقان‌ها با استفاده از نماهای مختلف داده شامل حوزه زمان، حوزه فرکانس، حوزه زمان-فرکانس و نمای صوتی مورد بررسی قرار گرفت. برای هر نما مدل‌های MLP آموزش داده شدند و سپس دو رویکرد اصلی فیوژن یعنی فیوژن در سطح ویژگی (Feature-level Fusion) و فیوژن در سطح تصمیم (Decision-level Fusion) ارزیابی شدند.
- نتایج حاصل بیانگر نکات زیر بودند:
- استفاده از تمام ویژگی‌ها به صورت مستقیم منجر به دقت نزدیک به ۱۰۰% شد، اما برای بررسی تفاوت میان نماها، حجم داده و تعداد ویژگی‌ها عمدتاً محدود شد.
 - هر ویو به تنها یک قادر به شناسایی الگوهای مربوط به خرابی بود، اما ترکیب آن‌ها منجر به بهبود چشمگیر عملکرد گردید.
 - فیوژن در سطح ویژگی به دلیل ترکیب مستقیم ویژگی‌های استخراج شده از تمام نماها، بالاترین دقت را ارائه داد؛ هرچند این روش به هزینه محاسباتی بالاتر و خطر بیش‌برازش (Overfitting) در داده‌های محدود حساس است.
 - فیوژن در سطح تصمیم از نظر محاسباتی سبک‌تر است و به دلیل استقلال مدل‌ها از یکدیگر، در برابر بیش‌برازش مقاوم‌تر بوده و قابلیت تعمیم‌پذیری بیشتری دارد. این ویژگی آن را برای کاربردهای صنعتی با محدودیت منابع مناسب‌تر می‌سازد.
 - نمای صوتی به تنها یک در ساختار ساده MLP دقت پایینی داشت، اما بررسی ویژگی‌های آکوستیکی مانند Spectral Centroid و Spectral Entropy نشان داد که این نما در کنار داده‌های ارتعاشی می‌تواند نقش تکمیلی ارزشمندی ایفا کند. در نهایت می‌توان نتیجه گرفت که ترکیب نماهای مختلف در قالب رویکردهای چندنما (Multi-View Learning) مسیر مناسبی برای بهبود دقت و پایداری سامانه‌های تشخیص خرابی است. علاوه بر این، با بهره‌گیری از روش‌های یادگیری عمیق و استفاده مستقیم از ورودی‌های خام در نماهای مختلف شامل داده‌های ارتعاشی در حوزه زمان و فرکانس و همچنین داده‌های صوتی در قالب نمایش‌های یکبعدی و دو بعدی (مانند Spectrogram و Scalogram) - می‌توان به نتایج بسیار دقیق و قابل اتقانی در پایش وضعیت و تشخیص خطای یاتاقان‌ها دست یافت.